



ML Enablement Workshop: ML Input module #1

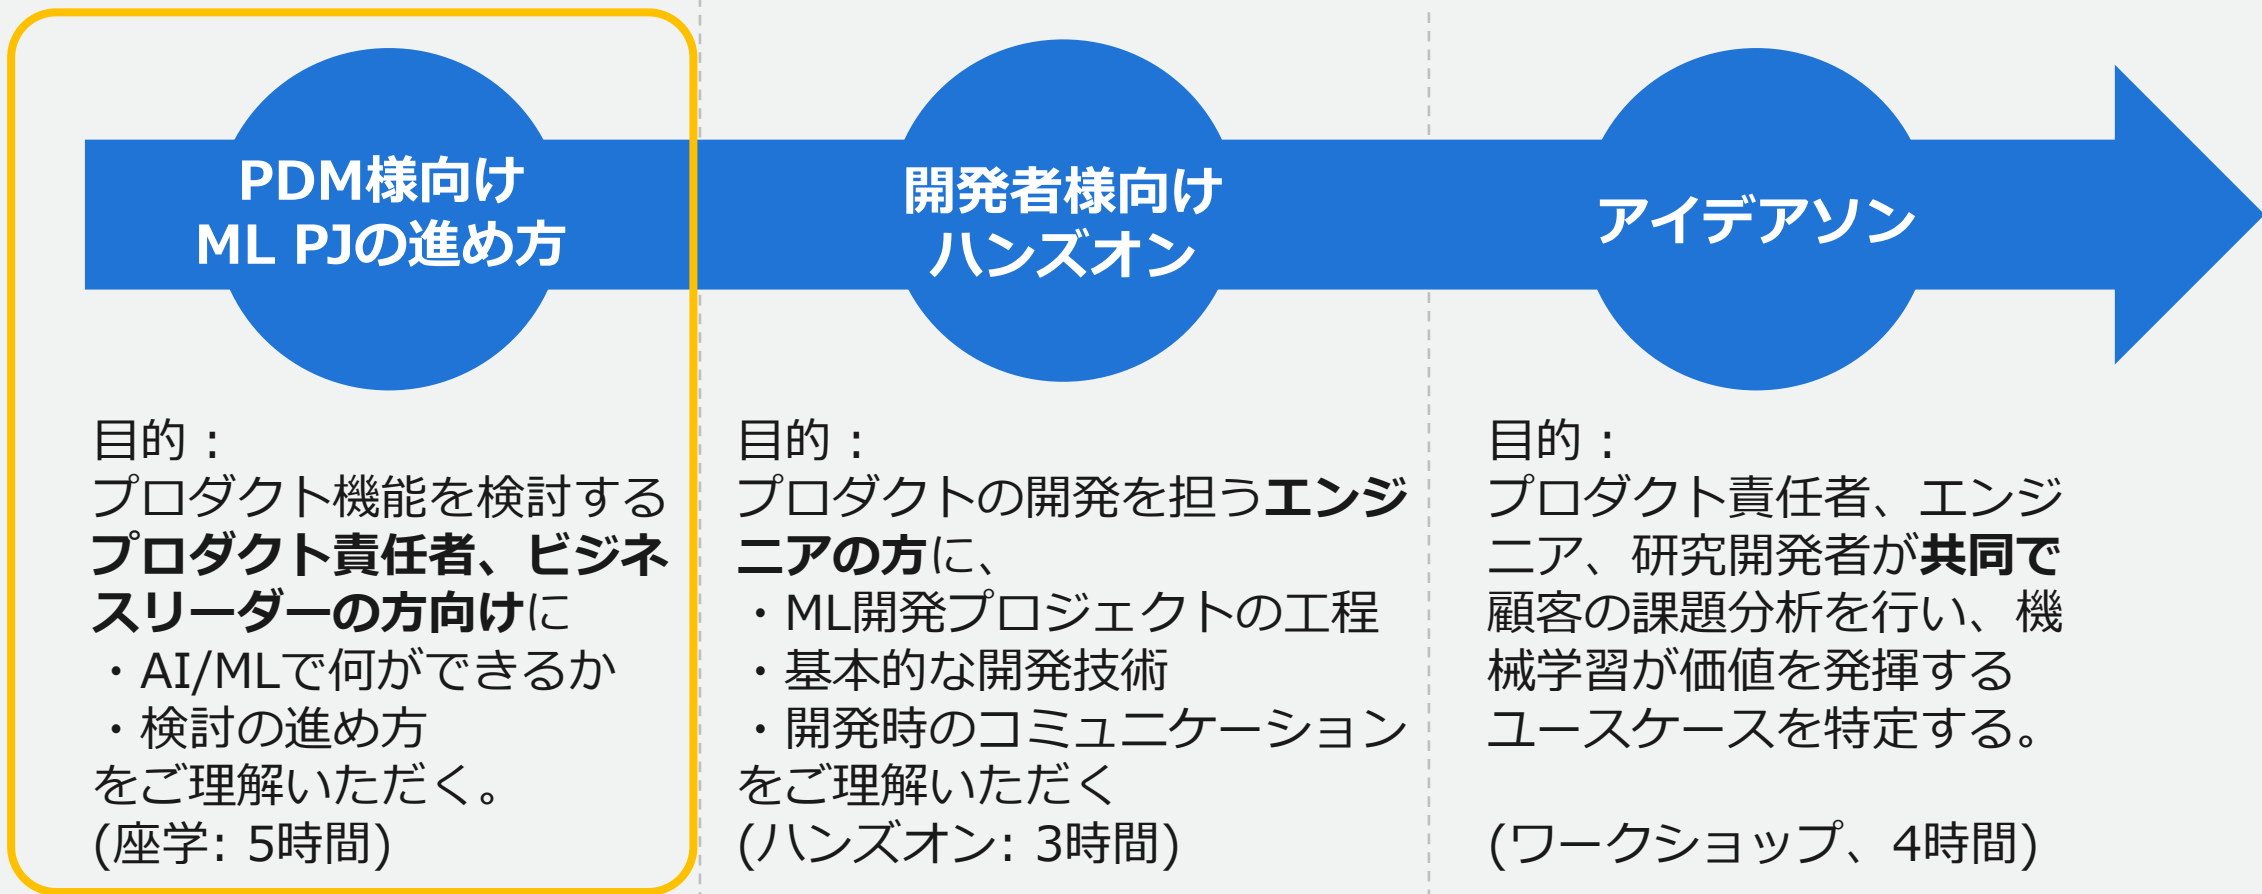
MLの入門

久保 隆宏

Developer Relation
Machine Learning

ML Enablement Workshopとは

プロダクトを開発するチームが、課題解決の選択肢として機械学習を選択できるようになることをゴールとしたワークショップです。



本日のインプットの対象者とゴール

誰のためのセッション?

MLプロジェクトに携わる**ビジネスリーダー、意思決定者**
(携わる予定のある方を含む)

何ができるようになるためのセッション?

課題解決策を検討するとき**MLの適用可能性を除外せず、**
実現プランを考え現状足りないものに気づけるようになること。

何ができるようにはならない?

機械学習アルゴリズムの実装。

本日のインプットの内容

MLの入門

MLの可能性

AI/MLとは

MLの活用事例

MLの技術的制約

MLプロジェクトの 計画

ユースケースの特定

ML拡大の要件

データの要件

期間・実用化の要件

ML活用組織への シフト

堅牢なAI戦略

データ戦略

組織内のコラボレーション

推進のためのリーダーシップ

参加者への期待




参加は
成功へのカギ

グループをエンゲージしよう
積極的に質問しよう



オープン
マインド



楽しもう

本コースのアウトライン

MLの入門

MLの可能性

AI/MLとは

MLの活用事例

MLの技術的制約

MLプロジェクトの計画

ユースケースの特定

MLの要件

データの要件

期間・実用化の要件

ML活用組織へのシフト

堅牢なAI戦略

データ戦略

組織内のコラボレーション

推進のためのリーダーシップ

1. MLの可能性

2. AI/MLとは

3. MLの活用例


4. MLの技術的制約

AI/MLはだれが使っている？

唐突な短いクイズ！

今日、朝起きてから今の時間までに、
AI/MLを使用したアプリケーションを使った方！

あなたがAI/MLの利用者です！




ライドシェア (例: Uber, Lyft)

待ち時間、需要予測、価格設定



オンラインショッピング

検索結果、商品レコメンド



金融機関

書類（小切手等）の認識
クレジット・デビットカードの不正取引検知



2023年の世界

80億個以上のAI/ML搭載デジタルアシスタント

¹ <https://techjury.net/stats-about/ai/> ² <https://www.juniperresearch.com/press/press-releases/digital-voice-assistants-in-use-to-8-million-2023>

わたしです！




一家に一台

iRobotの導入事例


[AWS re:Invent 2020: Running machine learning workflows at enterprise scale using Kubeflow](#)

MLはあらゆる場面に

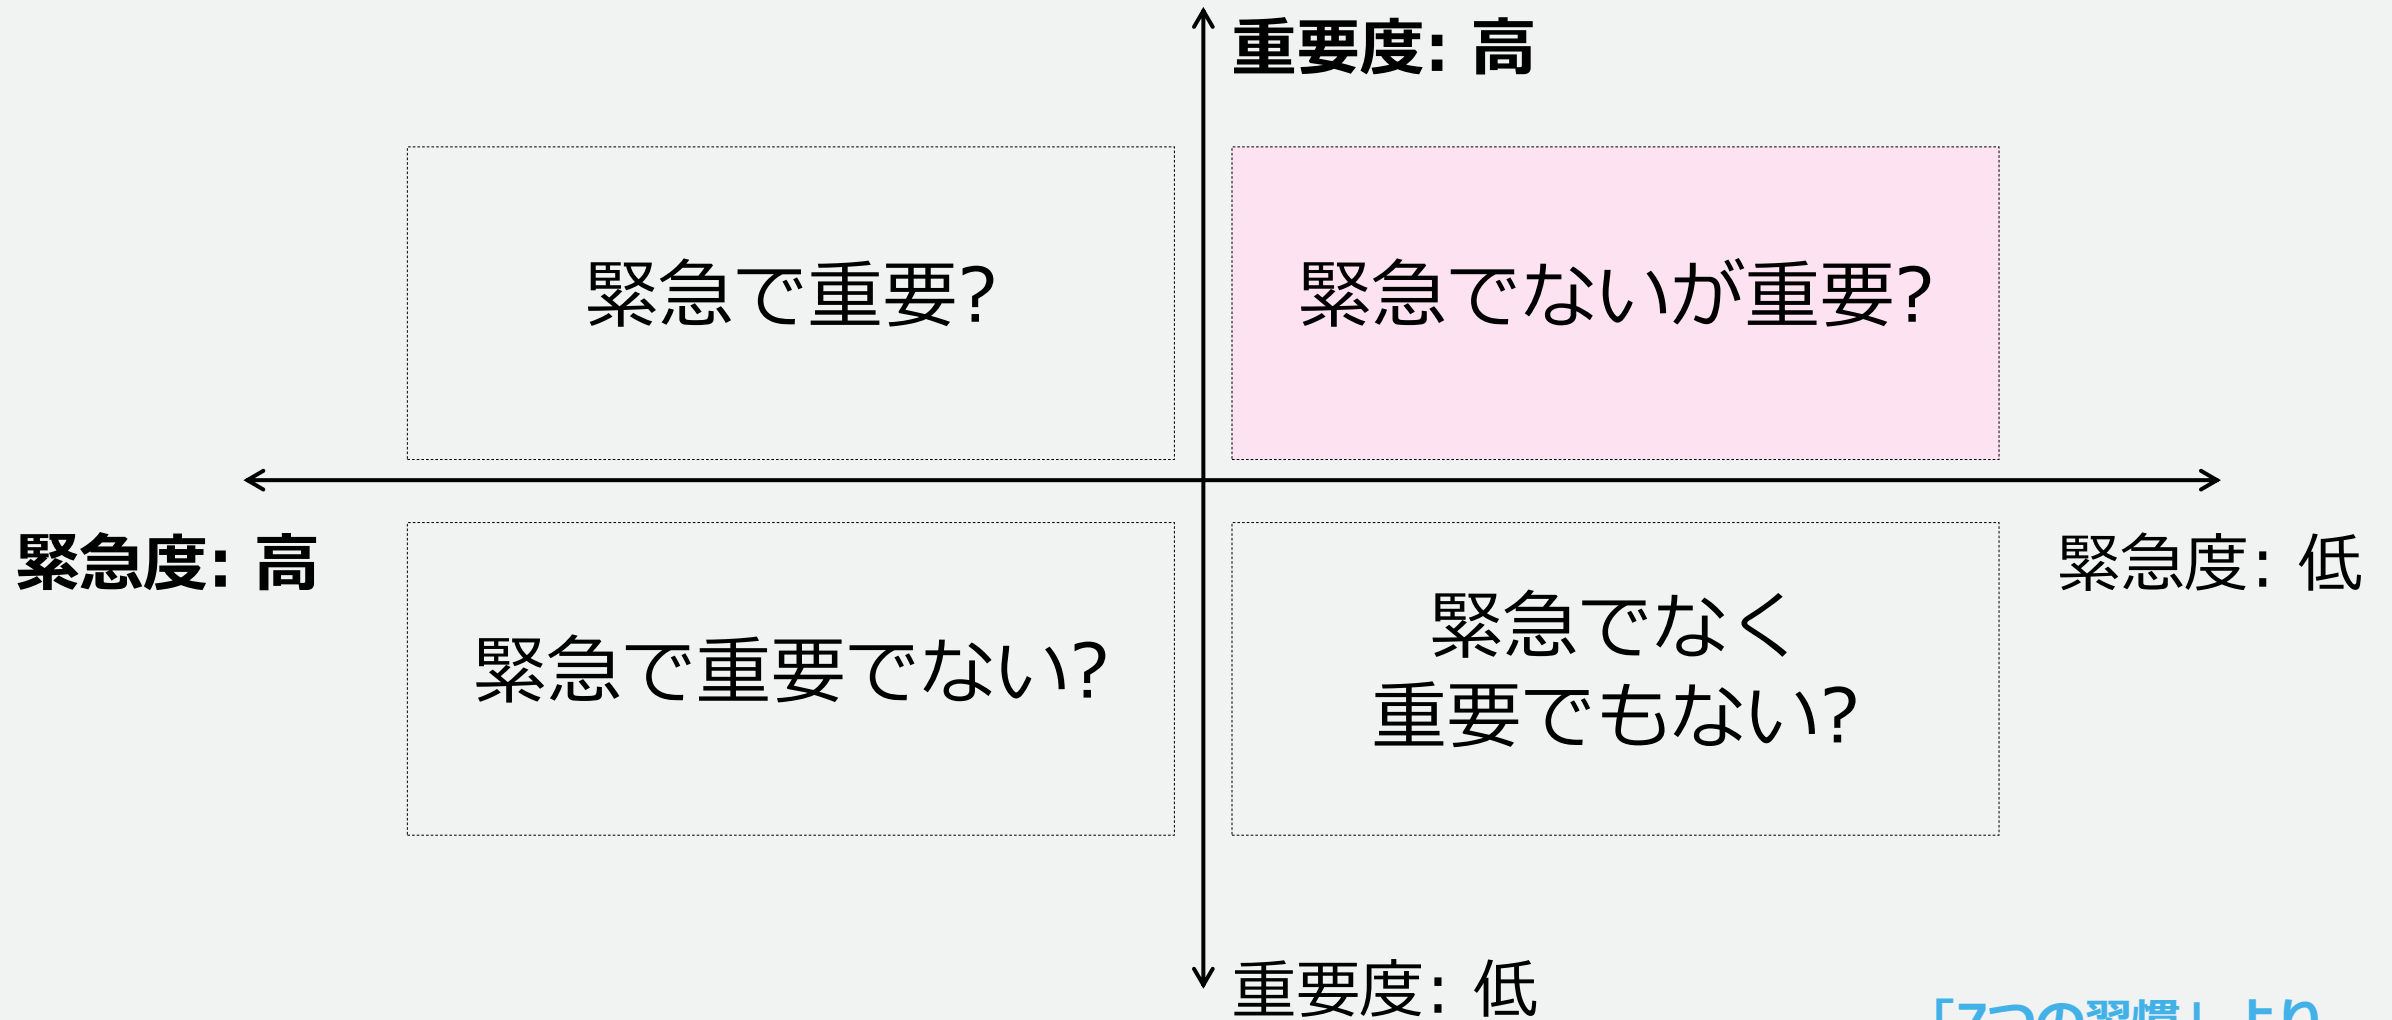


AmazonでのAI/ML適用例

AMAZON'S MACHINE LEARNING INNOVATION

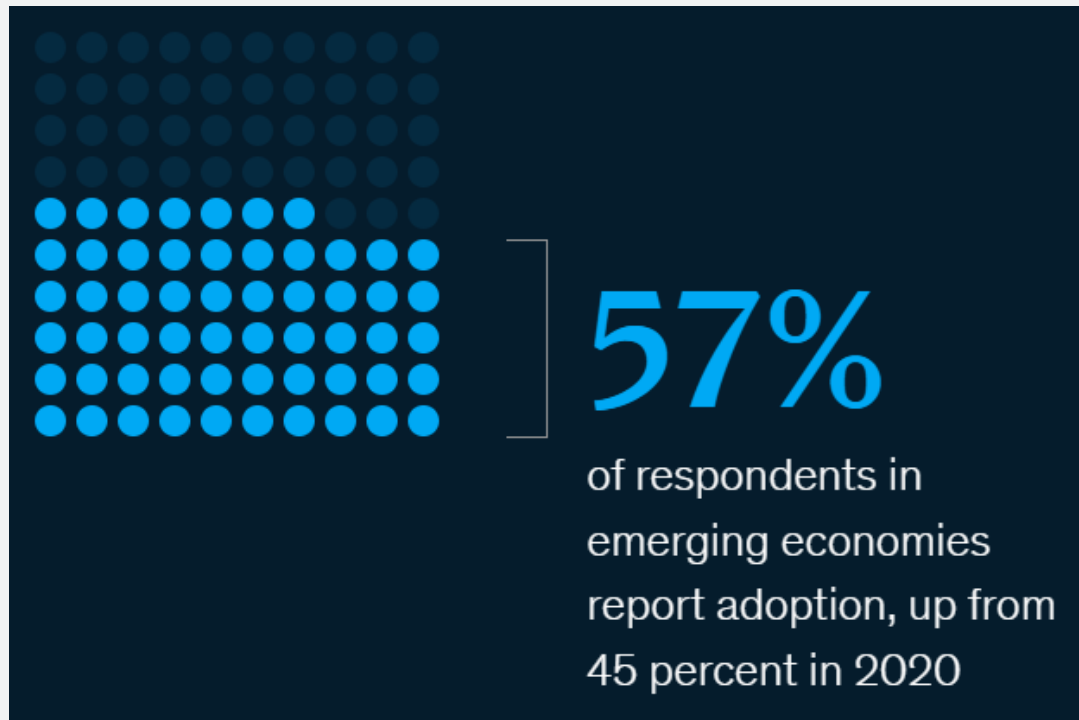


あなたのプロダクトにとって機械学習は？

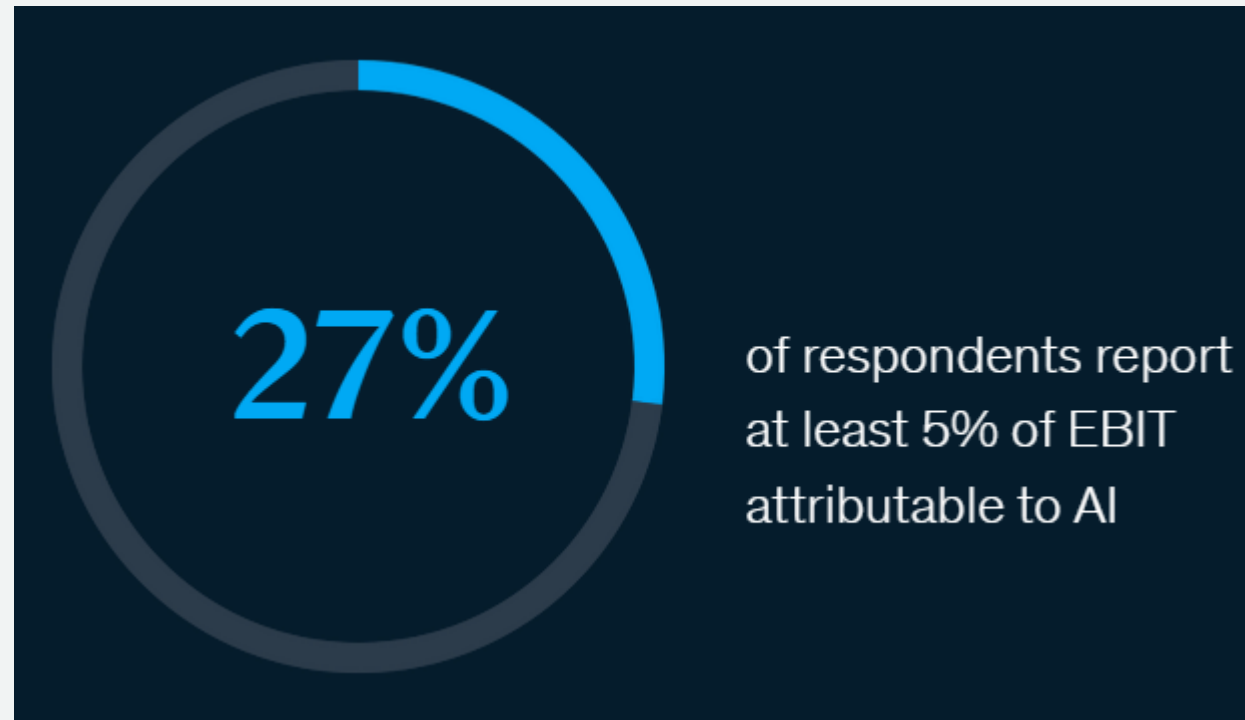


[「7つの習慣」より](#)

McKinsey Global Survey 2021 では、2020年からAIを適用した事例と効果が伸長。だんだんと事業に欠かせない技術となっている。





社内でAIを適用した事例が1つでもあると回答した企業が**45%から57%へ**



EBIT(利息及び税金控除前利益)の少なくとも5%がAIに起因すると回答した企業が**22%から27%へ**

AI白書2022によれば、日本でのAI活用は伸びているものの得られている効果は米国企業の4~5分の1に留まります。




AIを導入している企業は、2020年の4.2%から2022年の20.5%へ大幅に伸長

得られている売上増加、コスト削減の効果は米国に比べ大きく下回る。



AIにかかわる人材の不足は2022年一位に上げられており、特にAIに理解がある経営・マネジメント層の不足が深刻です。


図表②-18 AI人材の充足度



米国では半数近くが十分いると回答している一方、日本ではわずか4.9%(10倍近くの差)。

1. MLの可能性
2. AI/MLとは
3. MLの活用例
4. MLの技術的制約

AI/MLとは?




人工知能 (Artificial Intelligence, AI)

人間の知的判断をコンピュータ上で実現するための技術全般
(ロジック、if-then文、機械学習 (深層学習を含む))



機械学習 (Machine Learning, ML)

AIの一種であり、知的モデルを構築するためにデータの中の傾向を学習する技術



深層学習 (Deep Learning, DL)

MLの一種であり、音声・画像認識などのタスクを深い複数レイヤー構造のニューラルネットワークで実現する技術

従来型ソフトウェア vs. MLソフトウェア

人手で設計されたルール ➤

データ ➤



➤ 答え

演繹的

過去の回答 ➤
過去のデータ ➤



新しいデータ ➤



➤ 答え

帰納的

MLの実装には何が必要?

典型的なMLソリューションに必要なもの



ドメイン知識

例: 小さな食料品店の経営



データ

在庫・販売の記録



アルゴリズム

機械学習

MLの実装には何が必要?



①解決したい課題を機械学習のタスクとして定義する。タスクを解くための適切なアルゴリズムを選択する。
アルゴリズムは既成のものを使うときもあれば、独自に作る場合もある。


[Use Amazon SageMaker Built-in Algorithms](#)




②データを用い学習。




③学習したモデルで予測を実施。




アルゴリズムA




アルゴリズムB




アルゴリズムC



過去の回答/
過去のデータ



新しいデータ



モデル

MLの主な用語



モデル

MLアルゴリズムからの
のアウトプット

過去データをもとに
構築し、将来のデー
タに対し予測を行う




学習

過去のデータに基づ
くモデルの構築



検証

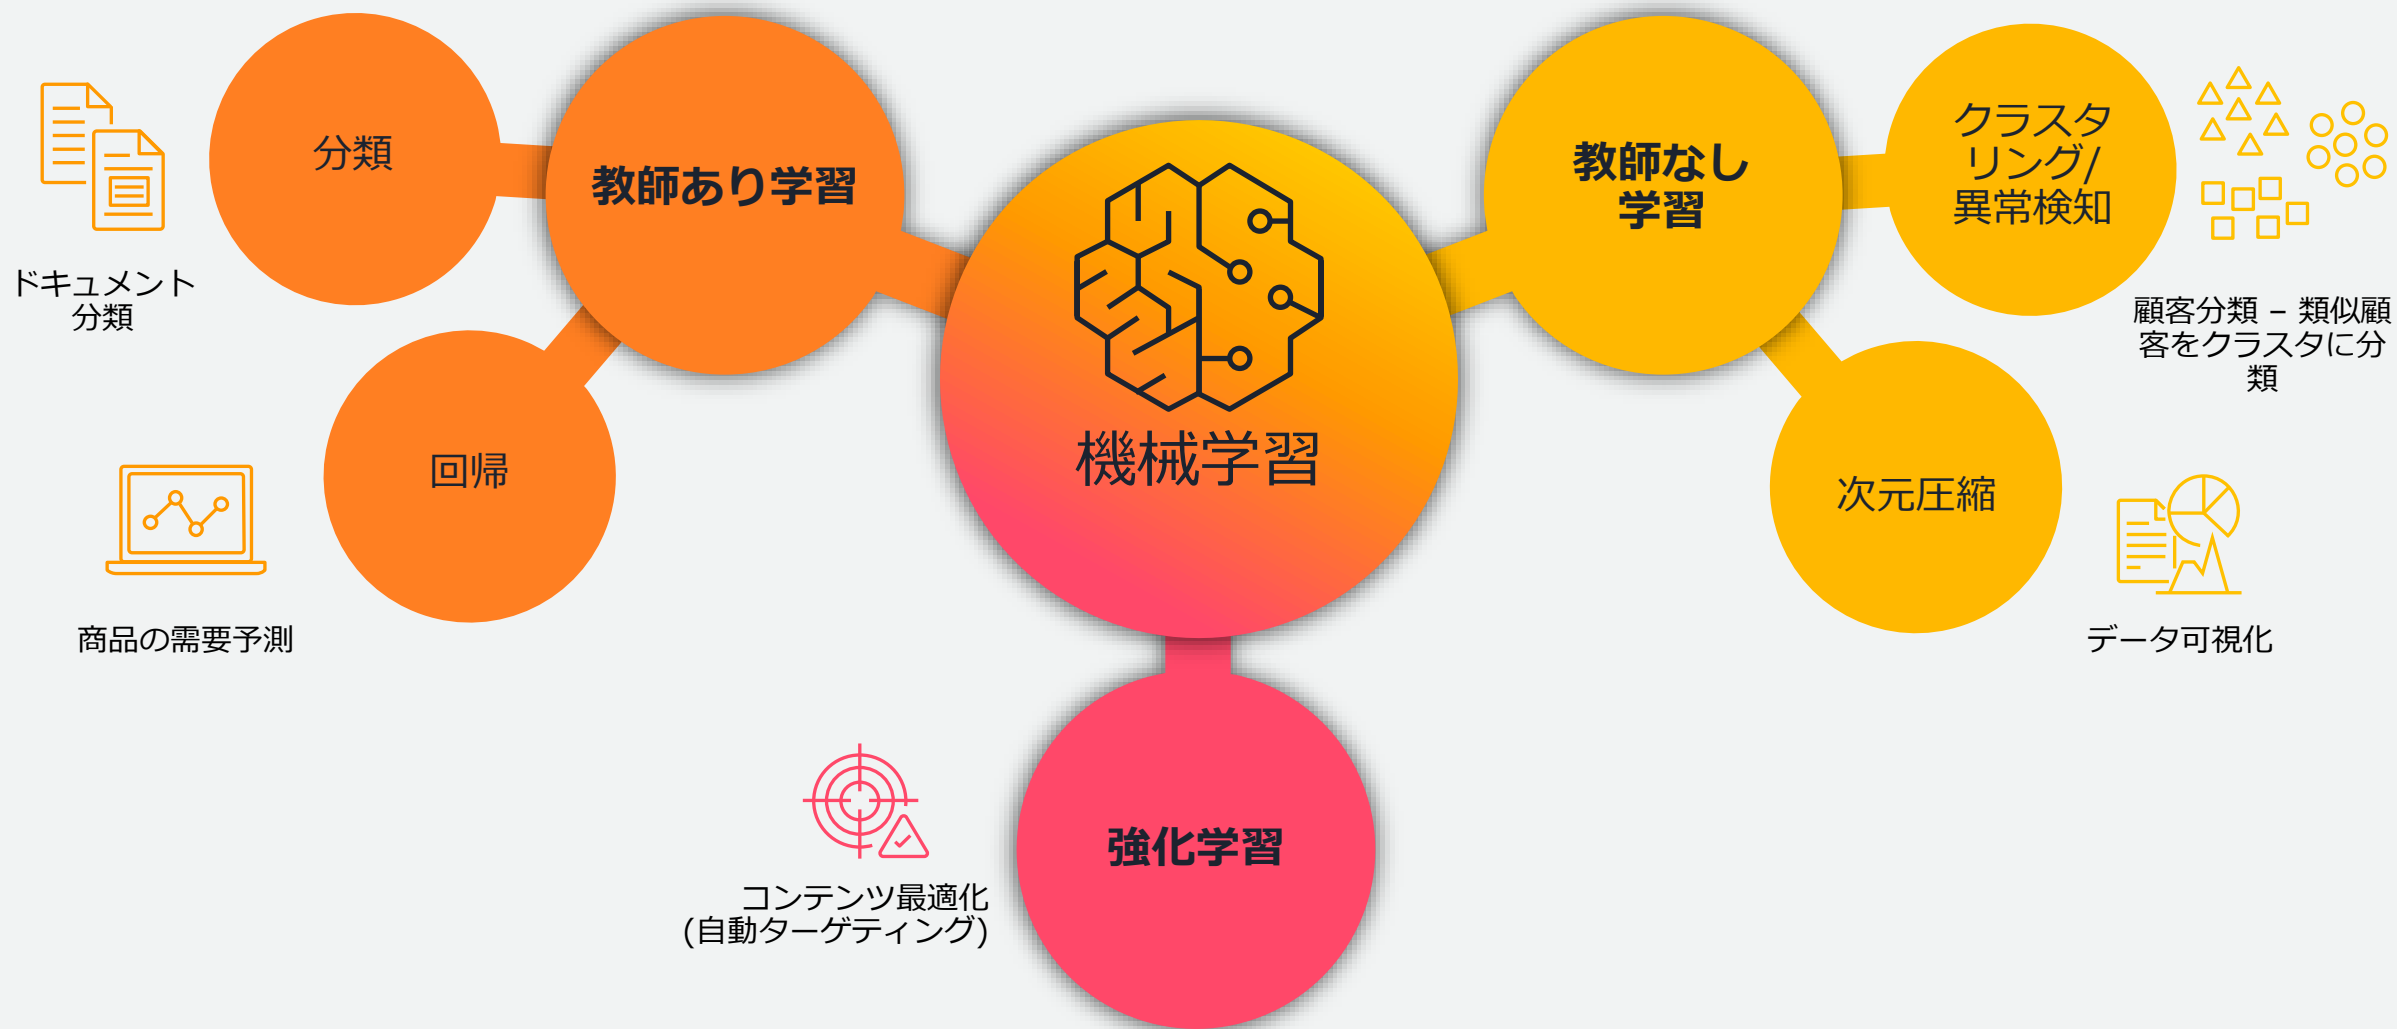
将来のデータに基づ
くモデルのパフォー
マンズの測定



デプロイ

プロダクションパイ
プラインへのモデル
の統合

モデルの学習方法とタスク



MLモデルの一般的なタスクとユースケース (1/6)

タスクの種類

ユースケース

事例

回帰

物件価格の予測

物件価格を予測

Zillow

Zestimate

\$1,496,442



ZESTIMATE RANGE

\$1.38M - \$1.62M



LAST 30 DAY CHANGE

+\$24,008 (+1.6%)

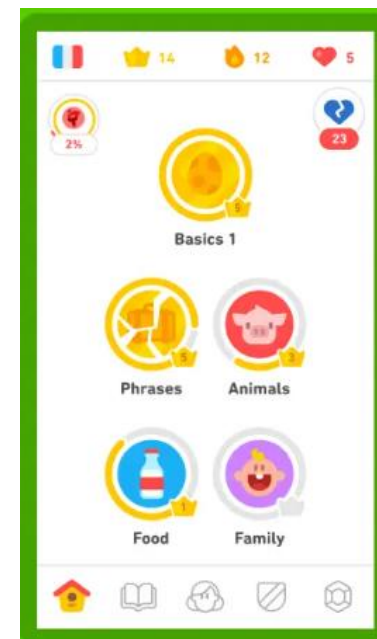
MLモデルの一般的なタスクとユースケース(2/6)

タスクの種類	ユースケース
回帰	物件価格の予測
分類	単語の分類

事例

見直しが必要な単語か否かを予測

duolingo



MLモデルの一般的なタスクとユースケース(3/6)

タスクの種類	ユースケース
回帰	物件価格の予測
分類	単語の分類
クラスタリング	画像内の顔パターンの発見

事例

アニメーションの自動タグ付け



MLモデルの一般的なタスクとユースケース(4/6)

タスクの種類	ユースケース
回帰	物件価格の予測
分類	単語の分類
クラスタリング	画像内の顔パターンの発見
異常検知	例外的パターンの発見

事例

新たな不正行為の特定



MLモデルの一般的なタスクとユースケース(5/6)

タスクの種類


ユースケース

事例

回帰	物件価格の予測
分類	単語の分類
クラスタリング	画像内の顔パターンの発見
異常検知	例外的パターンの発見
ランキング	選択されやすい順序の予測

検索結果の並び替え

ibotta




MLモデルの一般的な用途 (6/6)

タスクの種類	ユースケース
回帰	物件価格の予測
分類	単語の分類
クラスタリング	画像内の顔パターンの発見
異常検知	例外的パターンの発見
ランキング	選択されやすい順序の予測
レコメンド	選択されやすいアイテムの予測

事例

大規模イベント用ホテルの推薦



ナレッジチェック: MLのタスク

次のユースケースに適用できるMLのタスクは何?

回帰・分類・クラスタリング・異常検知・ランキング・レコメンド

- a) 人手による商品価格設定の効率化
- b) 偽造品の特定
- c) 誤って分類された商品の識別
- d) マーケティングセグメント特定のための顧客のグループ化
- e) コホート別顧客支出の予測

ナレッジチェック: MLのタスク

次のユースケースに適用できるMLのタスクは何?

回帰・分類・クラスタリング・異常検知・ランキング・レコメンド

- a) 人手による商品価格設定の効率化 – 回帰
- b) 偽造品の特定 – 分類
- c) 誤って分類された商品の識別 – 異常検出
- d) マーケティングセグメント特定のための顧客のグループ化 – クラスタリング
- e) コホート別顧客支出の予測 – 回帰

上記以外の方法がありますか？

1. MLの可能性
2. AI/MLとは
- 3. MLの活用例**
4. MLの技術的制約

Intuit: 問い合わせ回答待ちの時間を削減

BUSINESS NEED

Intuitには毎年1650万人以上の顧客からの問合せがあり、総対応時間は2.75億分/年にもものぼる。顧客は対応の待ち時間にいらついていた。

また、問い合わせは所得税申告の1月から4月に集中し、その間だけコンタクトセンターの対応要員を6,000から10,000にスケールさせる必要があった。

SOLUTION

問い合わせ内容を自動で「**分類**」し、対応するセルフサービス型のオンラインサポート機能を実装。コールセンターへの問い合わせを自動で書き起こし、業務を効率化。前者にAmazon Lex(チャットボット)とPolly(音声合成)、後者にContact Lens for Amazon Connect(機械学習による音声分析)を使用。

IMPACT

セルフサービス型オンラインサポートにより問合せコール数を削減。また、6カ月かかっていたコールセンターのスケールを2週間に短縮。

Intuit: 控除対象の経費を探す時間を削減

PROBLEM

Intuit社の主力製品「TurboTax」を用いて米国の所得税控除の申告書を作成する際、ユーザが控除対象となる項目の抽出に多くの作業時間を要していた

SOLUTION

顧客の1年間の銀行取引データを解析し、控除可能な経費を自動的に「**分類**」。
モデルの構築に Amazon SageMaker(MLモデルの開発環境) を活用し、「ExpenseFinder」という商品を開発。

IMPACT

ユーザの作業時間を数時間から数分に短縮。また、SageMakerの導入によってAI/MLを実用化するまでの期間を90%短縮（6カ月→1週間）。

Pomelo: 嗜好に合う商品を探す時間の削減

PROBLEM

創業以来同じ形式でWebサイト上に商品が表示されており、販売データの反映も遅かった。そのため、顧客は好みの商品を見つけることもトレンドの商品を見つけることも困難だった。

SOLUTION

個々の顧客向けにパーソナライズされた商品**レコメンド**を実装。レコメンドに使用するデータを最新化し、顧客の好みを数分で反映できるようにした。実装には Amazon Personalize(レコメンド)を活用した。

IMPACT

商品カテゴリページから個別商品へのクリックスルー率を18%向上し、商品カテゴリページからの収益を15%向上した。これにより、1カ月以内にROI 400%増加を達成。

MORE INFO: [CASE STUDY](#) | [VIDEO](#)



Fannie Mae: 債務不履行となる可能性を予測し貸倒を抑止

PROBLEM

ローン申請者の資産評価を行うため、毎日40,000件の評価レポートと50万枚の画像を受け取っていた。より適正な審査を行うためには、データに基づく判断を支援する適切なツールが不可欠だった。

SOLUTION

ローン審査業務の各工程で利用する予測モデル(**回帰**や**分類**)を構築。実装に Amazon SageMaker(MLモデルの開発環境) を活用。

IMPACT

業務を効率化するだけでなく、債務不履行の可能性のあるローン申請者の特定精度を3.5%から48%まで改善。モデルの透明性を維持するため、貸し手、投資家、アナリストのそれぞれに開発過程の可視化を実施。

MORE INFO: [ARTICLE](#)

Fraud.net: 新たな詐欺の手法を検知し不正利用被害を防止

PROBLEM

新たな詐欺の手口がどんどん開発されるため、顧客の不正利用被害を防ぐには多様な手口それぞれについて高い精度で検知する必要がある。しかし、現状では1つのモデルで**異常検知**しているため個々の手口の精度を高めることが困難だった。

SOLUTION

単一のモデルですべての不正に対応する方式から、不正ごとにモデルを構築する方法に切り替えた。これにより、個々の不正検知の精度を高めることができる。一方で、モデルの管理が煩雑になるため管理、運用を行うためAmazon Machine Learningを採用した。

IMPACT

個別の不正を正確に検知できるようになったことで、Fraud.netの顧客は1週間で100万ドルの不正被害を防止できるようになった。200ミリ秒以内での応答が可能になり、アプリケーションのレスポンスも改善された。

1. MLの可能性
2. AI/MLとは
3. MLの活用例
- 4. MLの技術的制約**

データの影響

データに偏りがあれば偏りのあるモデルが生成される

過去発生した事例

- 画像認識システムが黒人の写真に「ゴリラ」というタグを付けた
- 白人より黒人、男性より女性のジェンダーの分類を誤りやすい
- 発展途上国では物体認識モデルの精度が落ちる

著名なデータセットである ImageNet では、差別的なタグ付けがされたデータを含むことが指摘され2019年60万件近くのデータを削除

https://www.jst.go.jp/tt/journal/journal_contents/2021/12/2112-02_article.html



データの影響

(多くの場合)タグ付けされた同一形式のデータを一定量必要とする





必要なデータ量は、タスクの複雑性、転用可能なデータやモデルの有無により左右される。

MLの説明性



**MLアルゴリズムの中には説明性を有するものがある
その場合は、出力結果がどのように作られたのかを理解できる
ただし、全てのMLモデルがそうではない**

SIMPLE
MODEL



Tree

COMPLEX
MODEL



Car

説明性と精度との間には
トレードオフが見ら
れることが多い

説明性の不足

許容されない状況は？

- › 顧客に対し、ローン申請が拒絶された理由に対する説明が求められるとき
- › 取引が不正なものと判断された理由を説明する必要があるとき

許容される状況は？

- › 誤分類・誤判定のリスクが小さいとき（アイテムの表示順序など）
- › 最終判断が人間によって行われるとき

シンプルなモデル vs. 複雑なモデル



モデルがどのように使われ、説明性がどの程度求められるのかを意識する

- › 初期段階ではシンプルなモデルを試す。結果が理解しやすく、早く開発することが可能。
- › ビジネスにとって意味のあるベースラインを設定する。最先端技術の性能の必要性を見極める。

不確実性

モデルは過去のデータに基づき確率的に予測する。予測の傾向は、人間の判断と一致しないかもしれない。



どれが犬でどれがパンか？
人が間違える傾向とモデルが間違える傾向が一致するとは限らない

Module #1の復習

Module #1: MLの入門

- **MLの可能性**

- 誰もが利用している。77%のデバイスでMLが動いている。
- 日米ではMLの効果に4~5倍、経営層に10倍近い差があり、日本での機械学習の効果や人材は大きく伸びる余地がある。

- **AI/MLとは**

- 人工知能を実現する手段の一つとして機械学習があり、深層学習は機械学習の手法の一つ。
- 演繹的にルールを定義する従来のソフトウェアと異なり、データから帰納的に構築する。
- ドメイン知識、データ、アルゴリズムの3つが構築に必要。

Module #1: MLの入門

- **MLの活用事例**

- 回帰、分類、クラスタリング、異常検知、レコメンド等のタスクがある。
- 解きたい課題に合わせてタスクを選ぶ必要がある。

- **MLの技術的制約**

- データに偏りがあれば偏りのあるモデルが生まれる。
- 一定量のデータを必要とする。
- 説明性と精度はトレードオフになる場合がある。
- 挙動には不確実性がある。

TIME FOR A BREAK

See you in 5 minutes!

This material is based on the AWS Machine Learning Embark Program,
an immersive ML training program provided by Amazon Machine Learning Solutions Lab

