



ML Enablement Workshop: ML Input module #2

MLプロジェクトの 計画

久保 隆宏

Developer Relation
Machine Learning

本コースのアウトライン

MLの入門

MLの可能性

AI/MLとは

MLの活用事例

MLの技術的制約

MLプロジェクトの 計画

ユースケースの特定

MLの要件

データの要件

期間・実用化の要件

ML活用組織への シフト

堅牢なAI戦略

データ戦略

組織内の学習とコラボレーション
文化

推進のためのリーダーシップ

MLプロジェクトの計画のプロセス: Business Understanding

Business Understanding

ML対象ユースケースの特定

ビジネス課題を
定義する

課題解決のシナリオ
を描く

MLのプロセスを
特定する

ML対象

ML対象
ユースケース
リスト

既存の開発と同様

ML対象外のプロセスは
既存の開発で行う

要件の確認

MLの要件確認

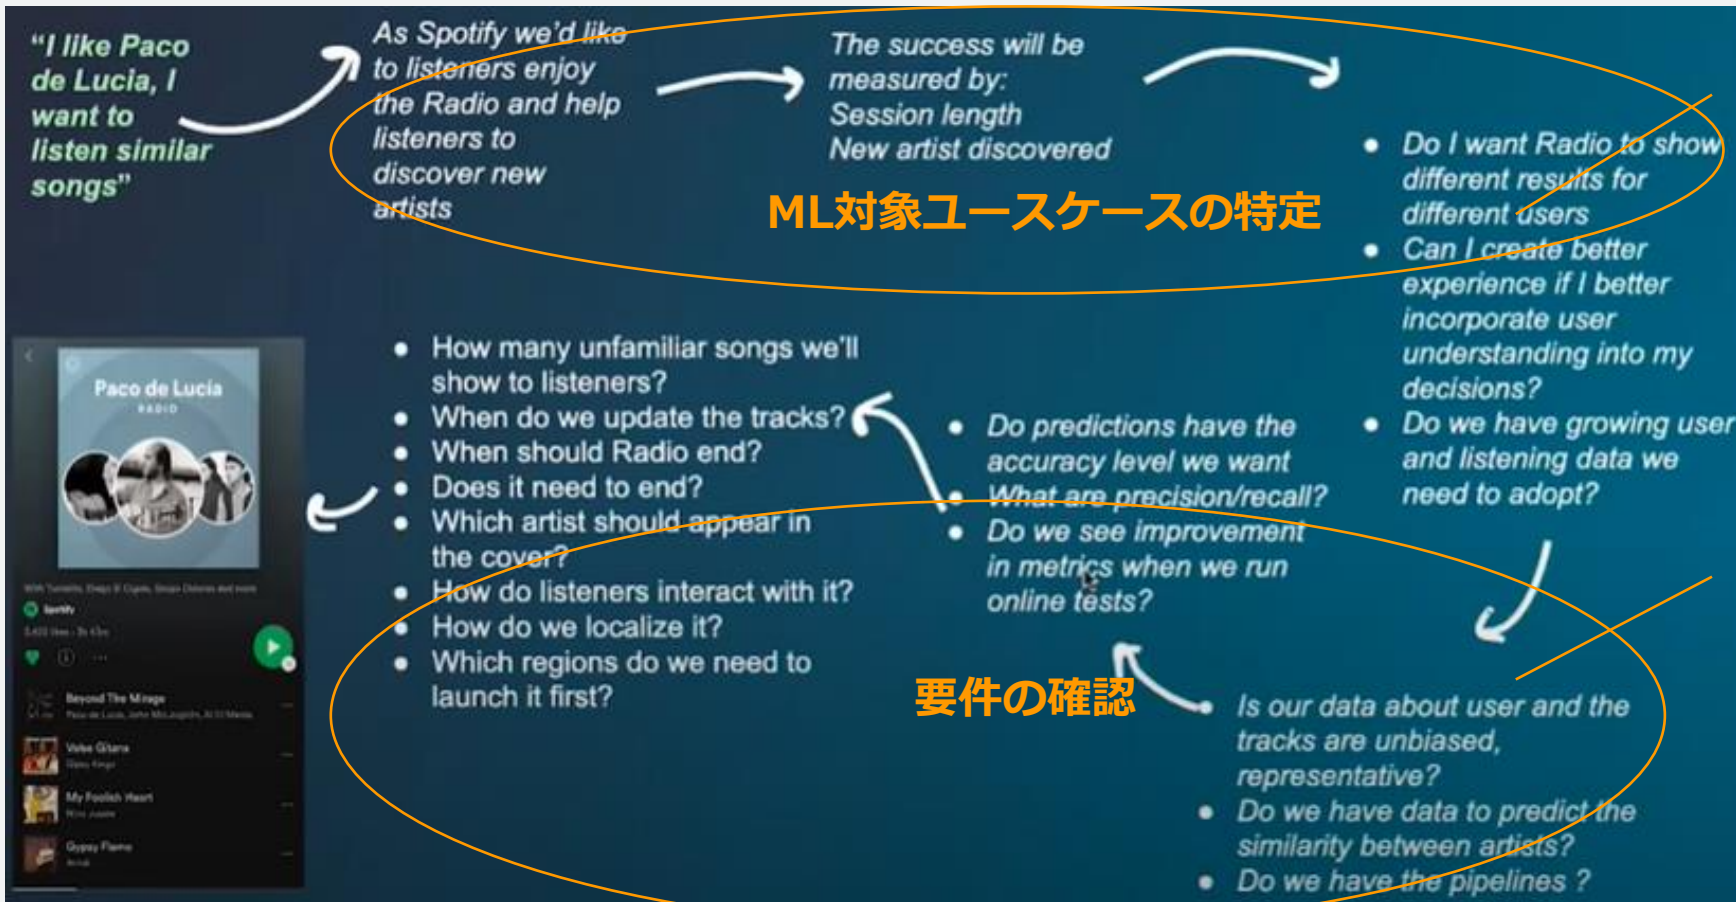
データの要件確認

期間・実用化の
要件確認

MLプロジェク
ト計画

開発へ

参考: Spotifyのレコメンド機能PdMのML計画プロセス



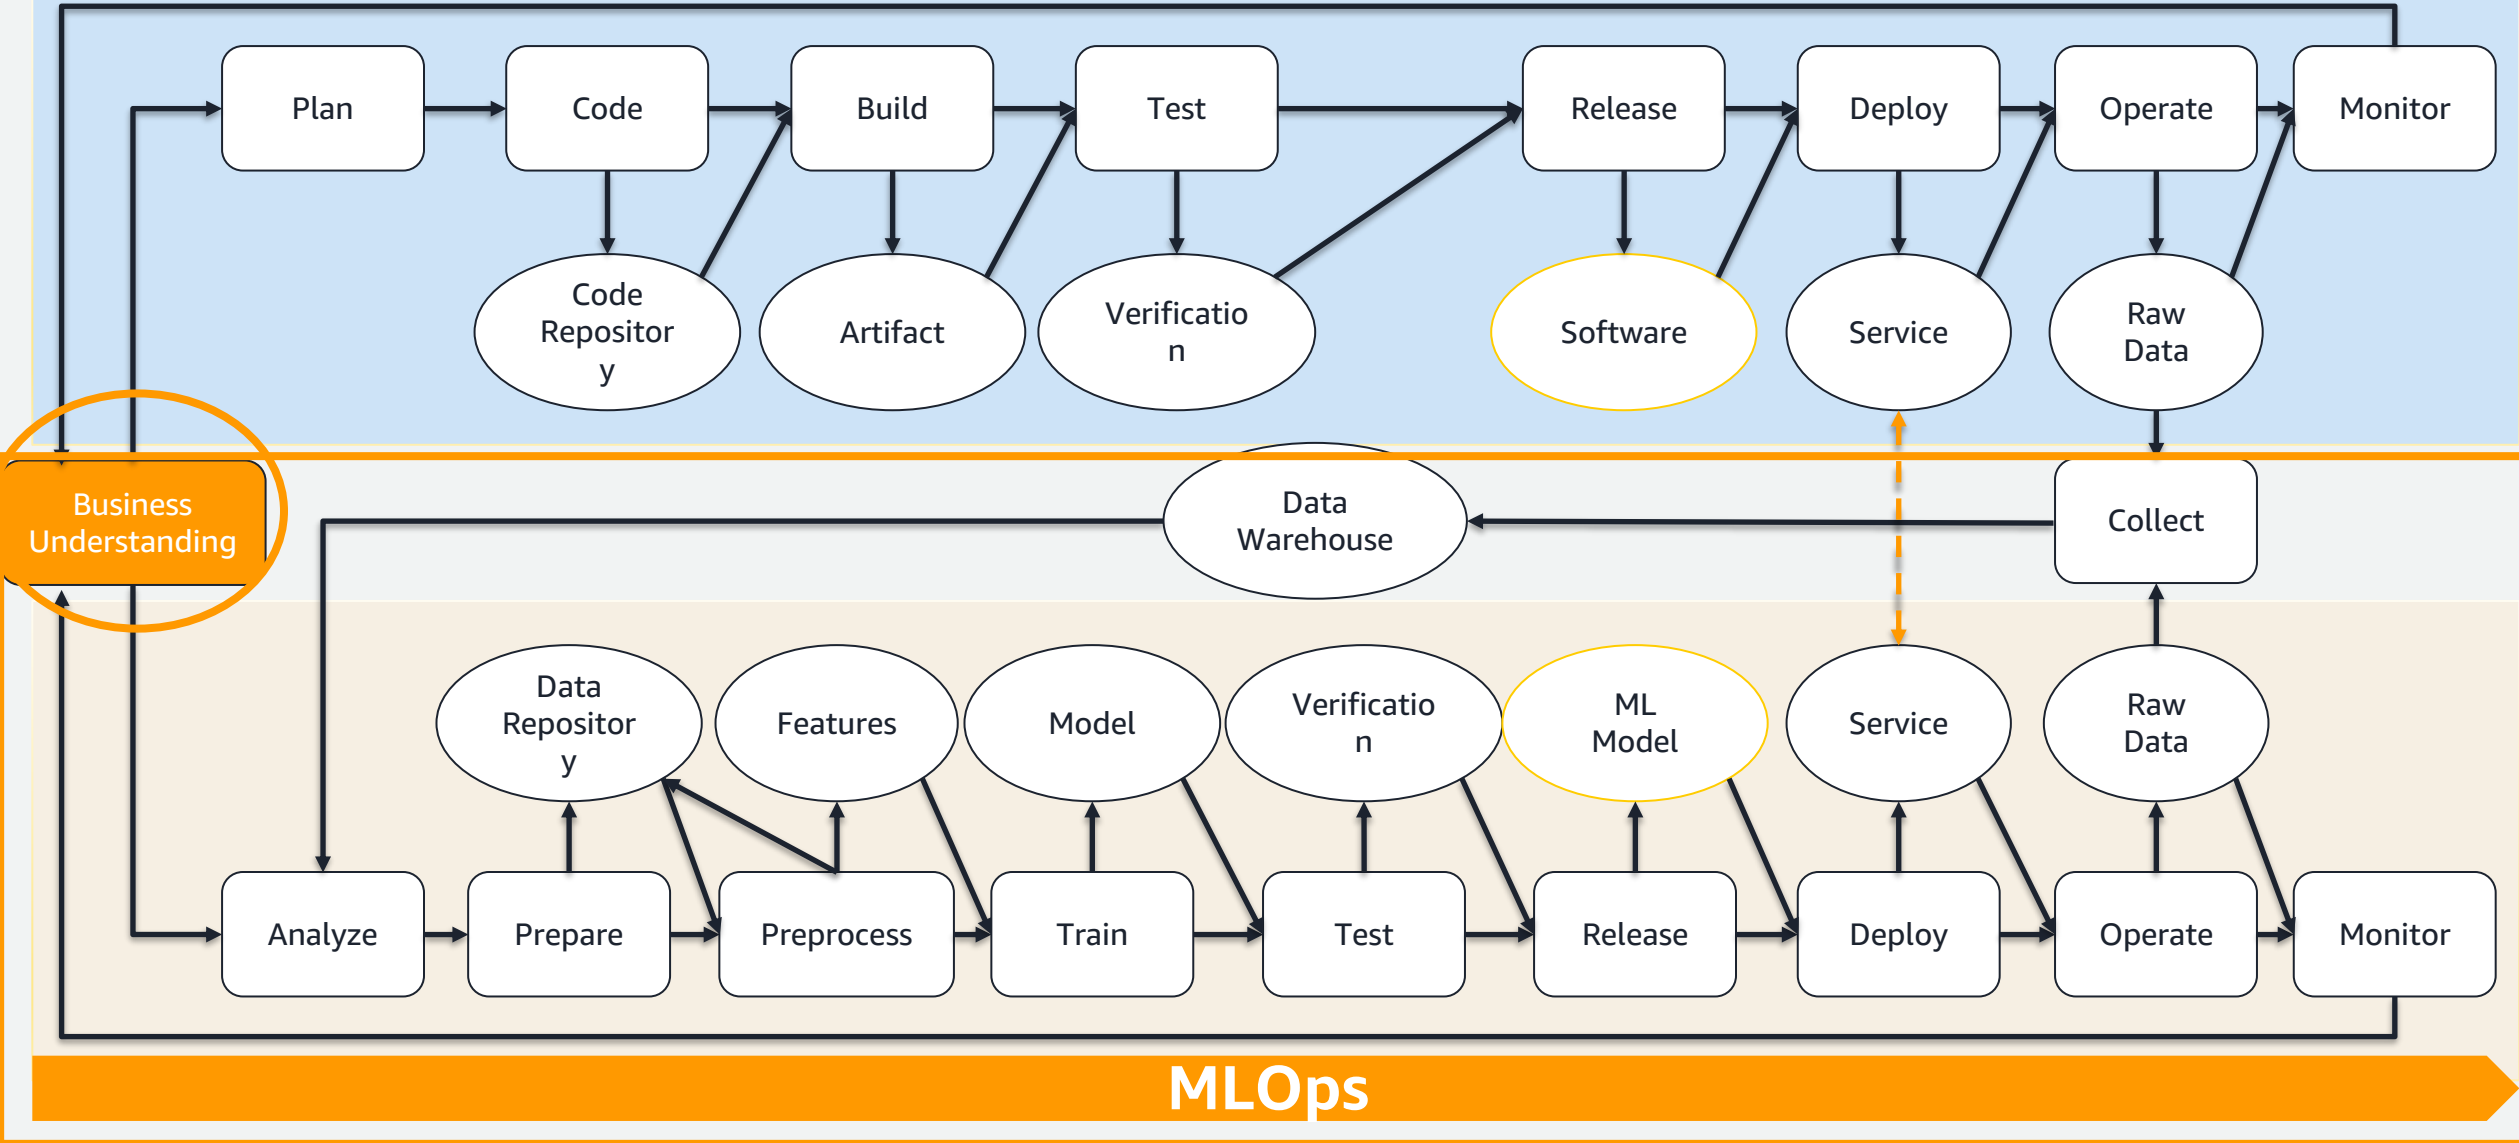
- 1) Paco de Lucia(アーティスト名)と似たアーティストの曲が聞きたい。
- 2) SpotifyとしてRadioを楽しむためアーティストの発見を助けたい。
- 3) Radioの機能に入れるべきか? よりよい体験に繋がるか?

- 1) データは十分蓄積されているか。バイアスはないか。
- 2) 精度は十分か。成功のメトリクスを観測できるか。
- 3) アプリのどこでMLによる新しいラジオを提案するか

Webinar: Managing Machine Learning Products by Spotify Product Leader, Derya Isler

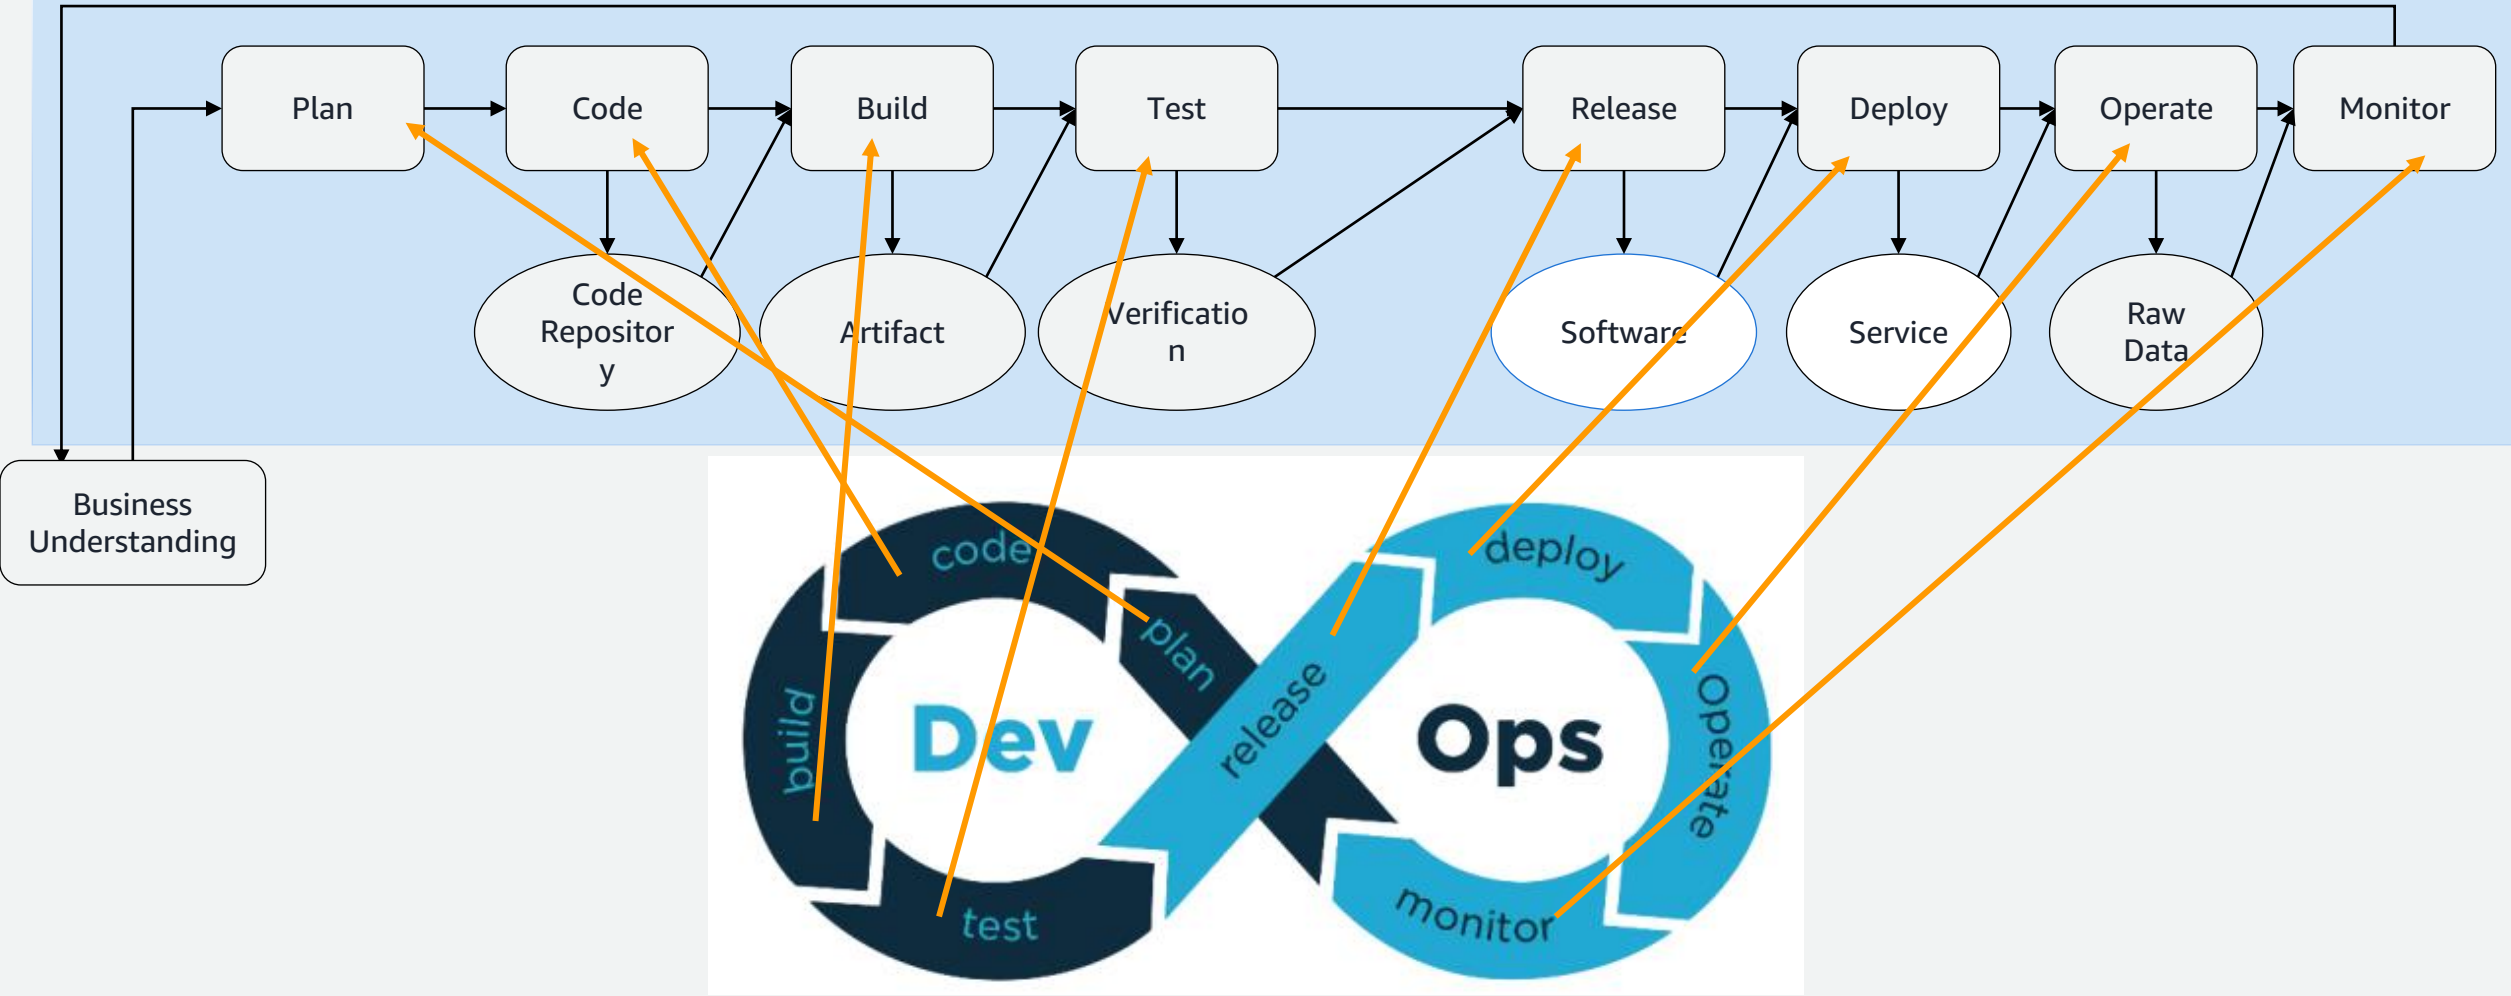
MLの開発が加わった開発プロセス

DevOps



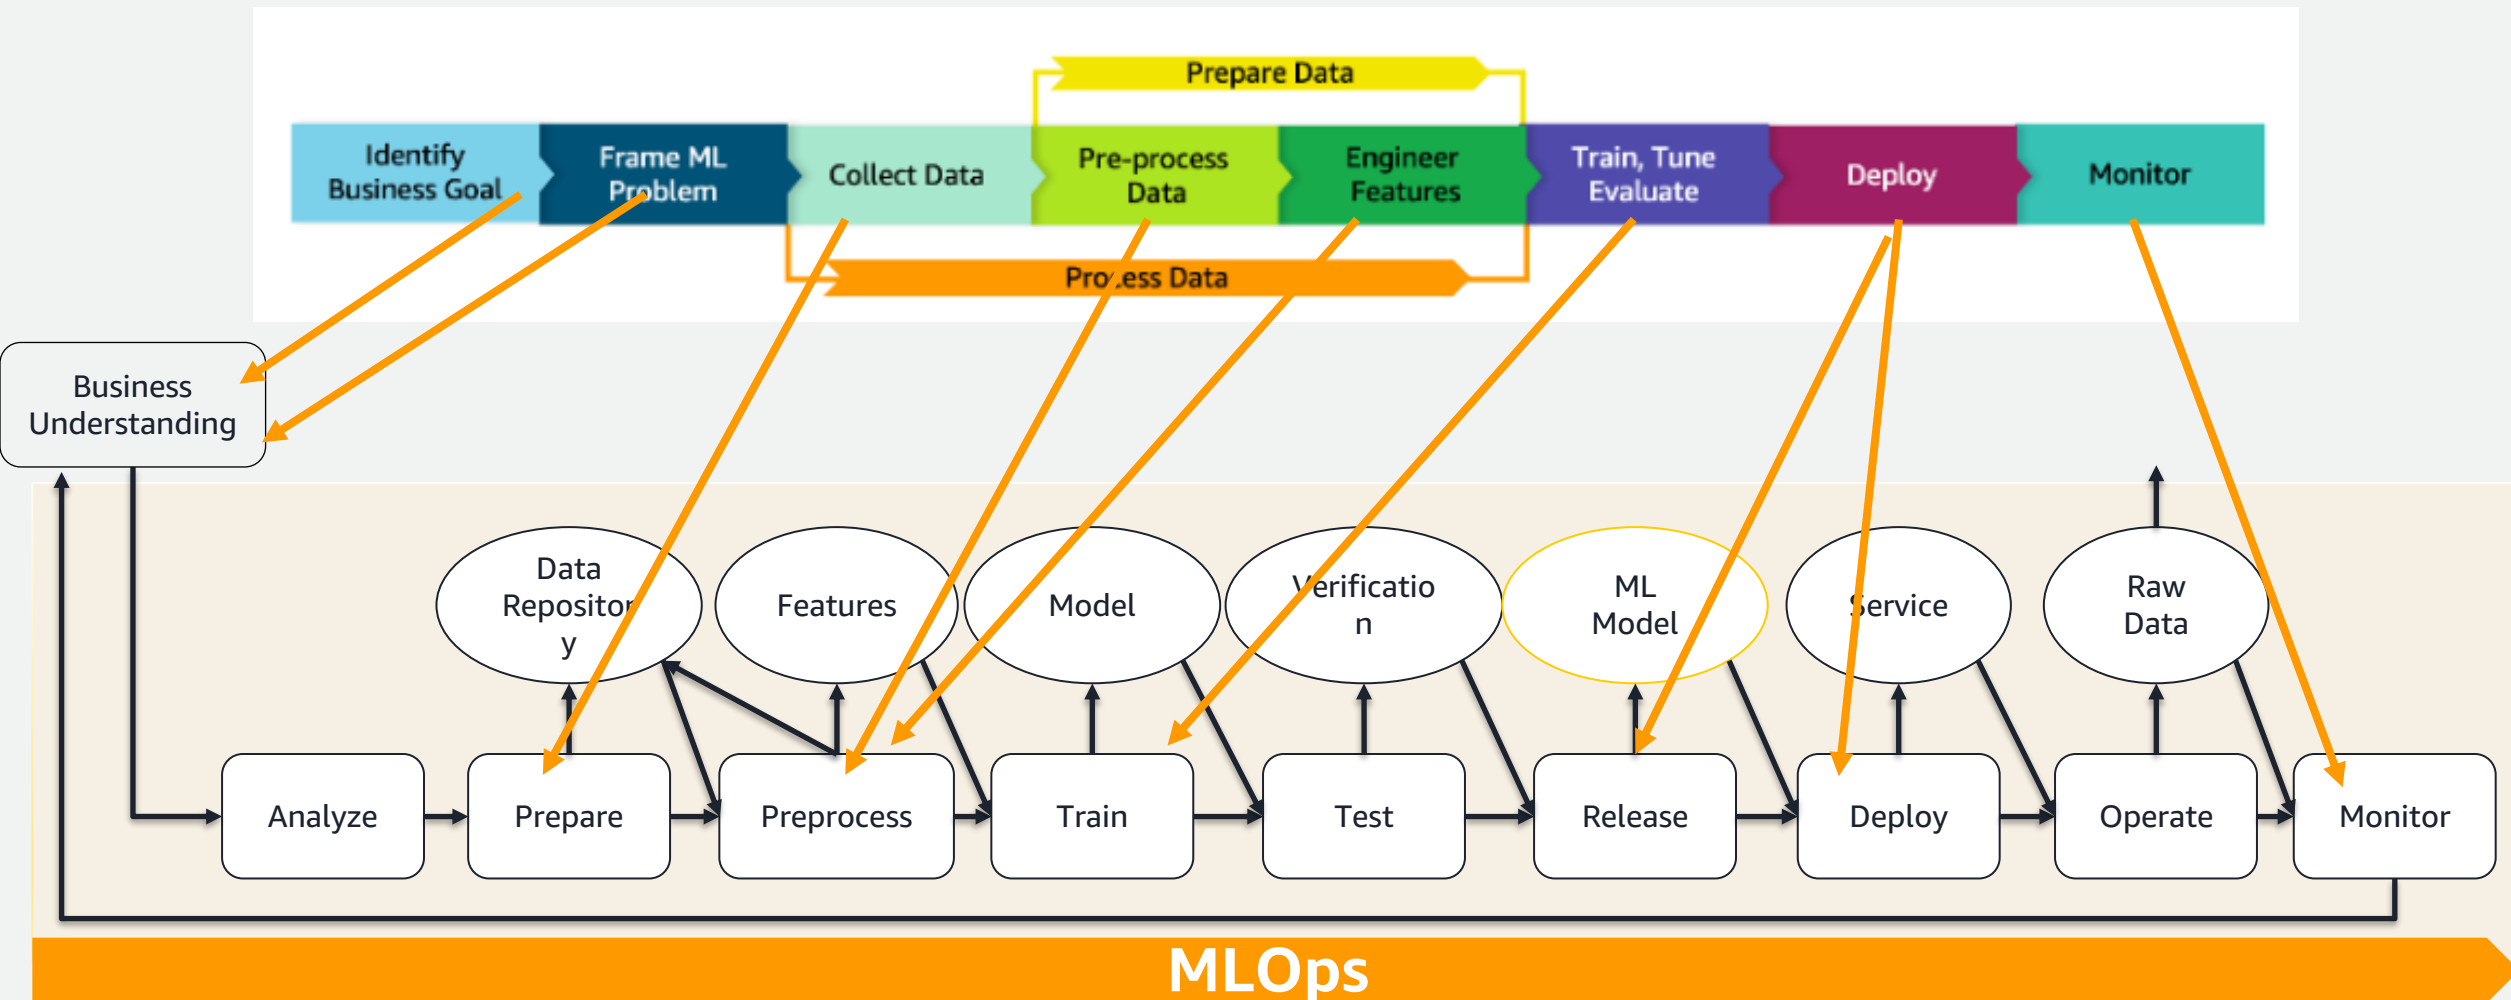
上段は既存のソフトウェア開発プロセス(DevOps)

DevOps



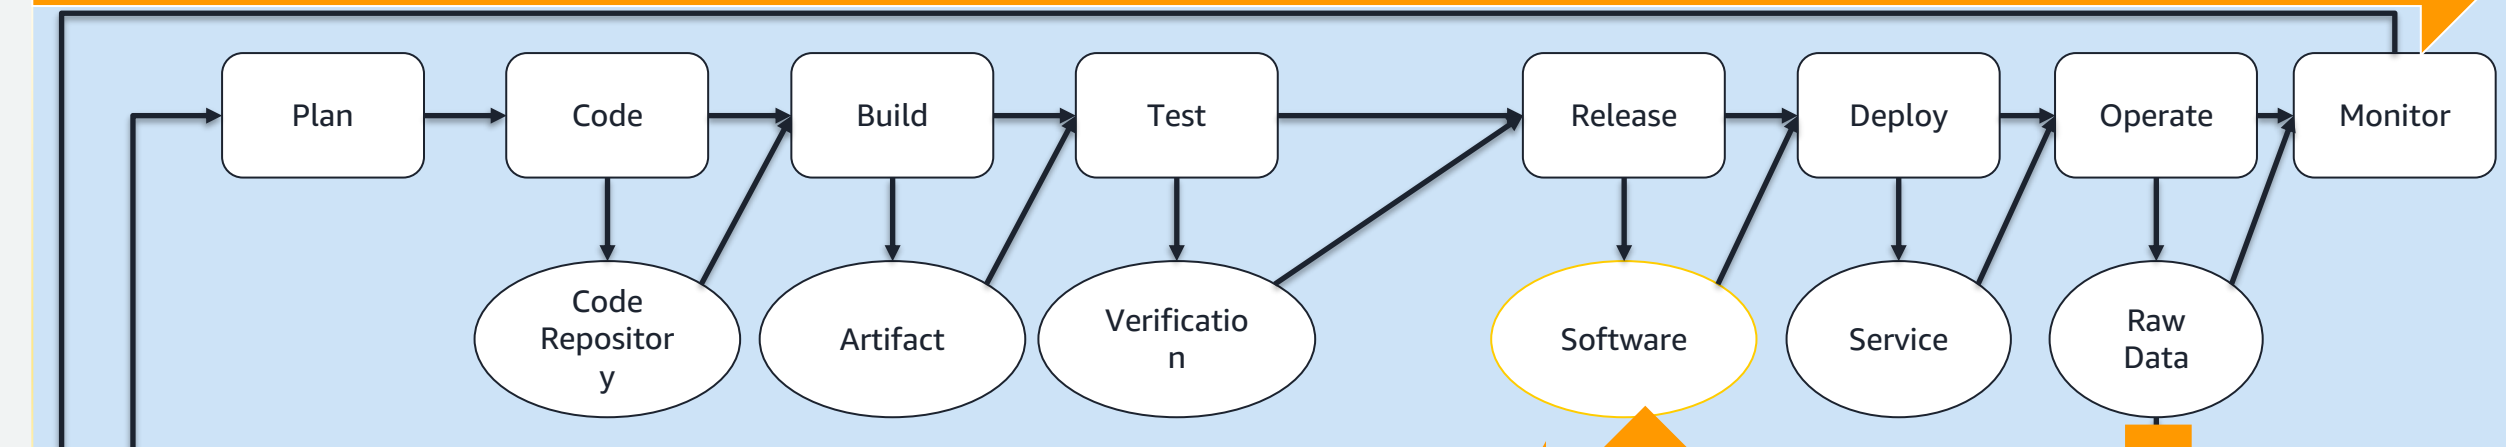
下段は機械学習モデルの開発プロセス(MLOps)

機械学習モデルの開発プロセス(MLOps)は、DevOpsほど定着した定義がまだない。AWSの定義([MLLens](#))を主に参照し、DevOpsのプロセス名と対応するよう定義。



蓄積されたデータから機械学習モデルを構築し、連携させる

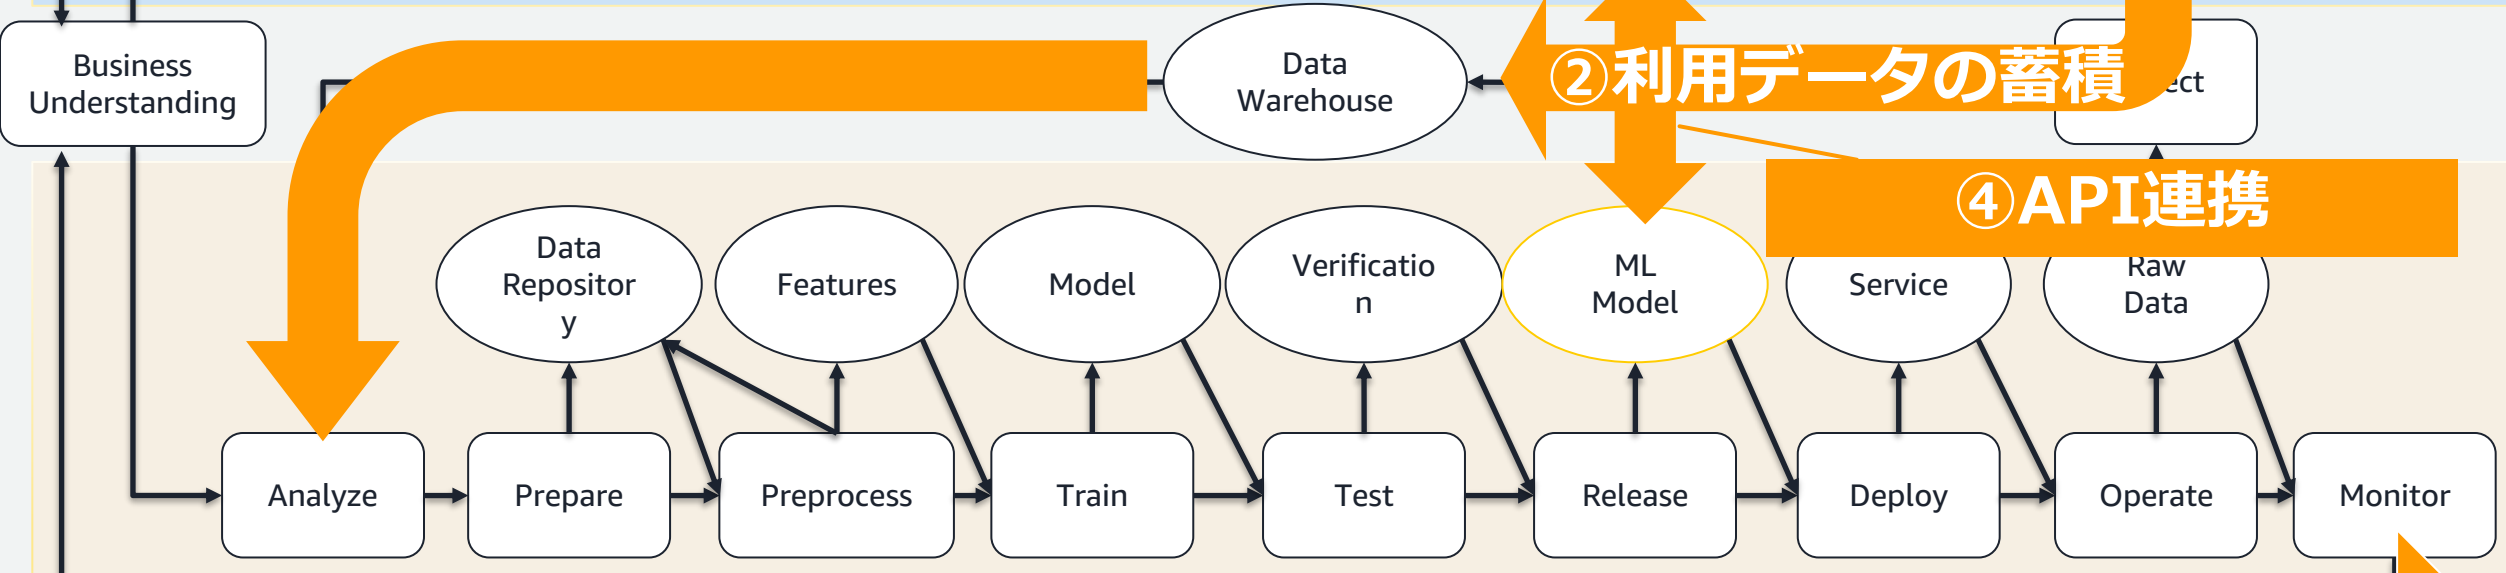
① DevOpsによるソフトウェア開発



② 利用データの蓄積

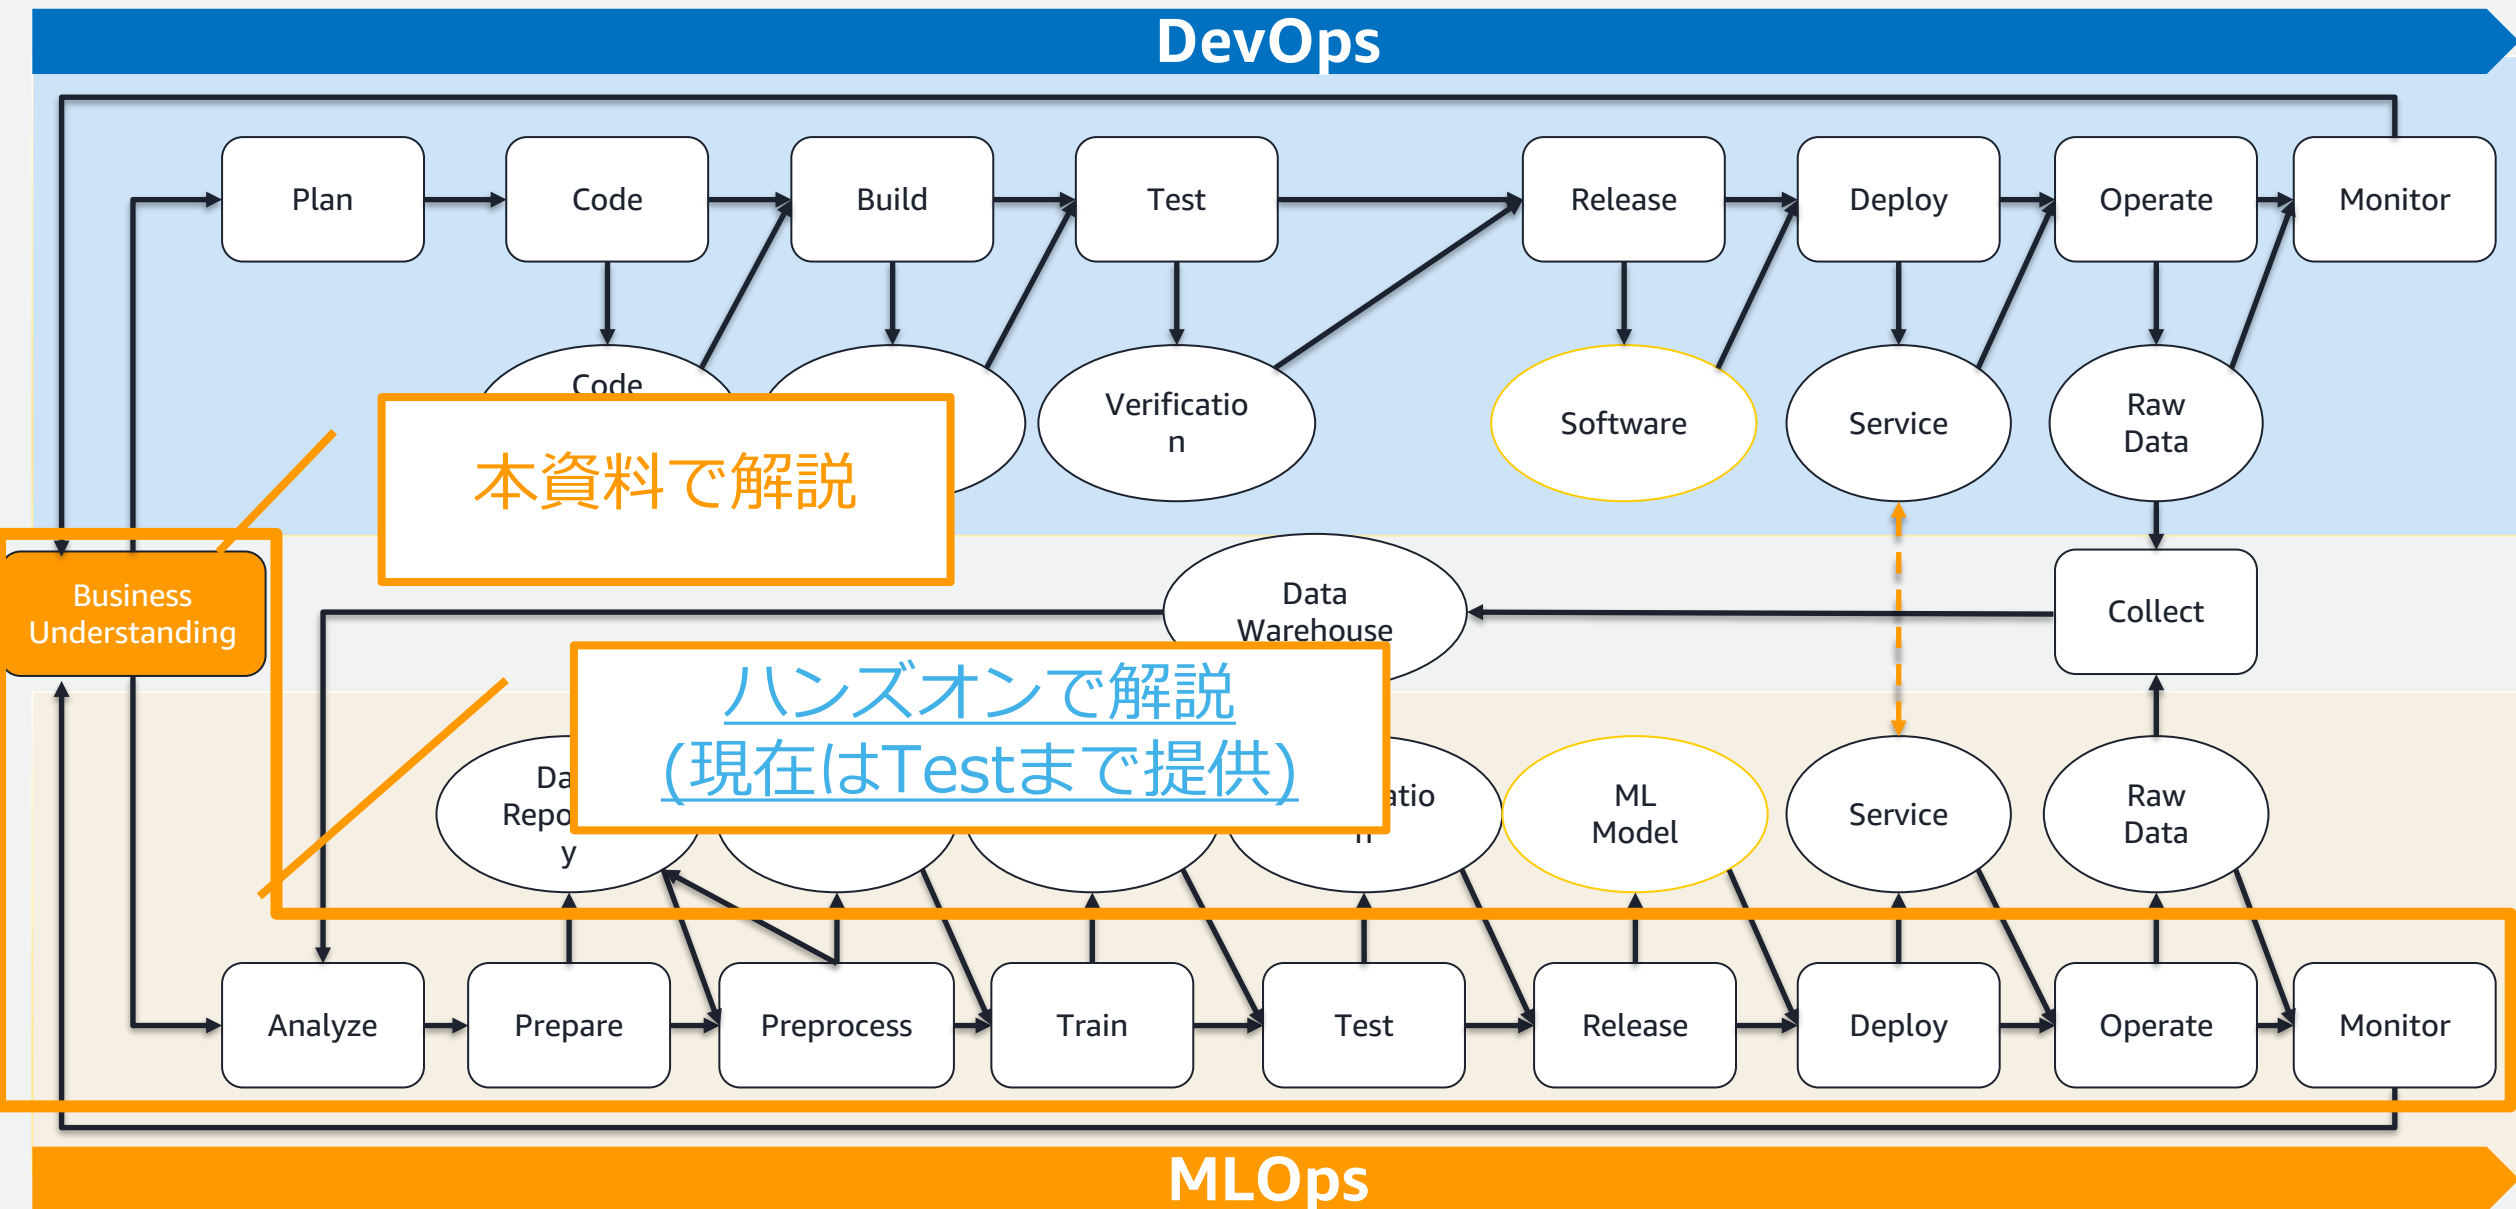
Data Warehouse

④ API連携



③ MLOpsによる機械学習モデル開発

本資料の解説範囲



1. ユースケースの特定

2. MLの要件

3. データの要件

4. 期間・実用化の要件

ML対象のユースケースを特定する

ビジネスゴールの策定から始める

組織全体で達成したいビジネスゴールをTo-beとして定義する。ビジネスゴールは具体的かつ測定可能にする。定義されたゴールを達成するためにMLが貢献するプロセスを3つのステップにより特定する。




ビジネス課題を定義する:

ビジネスゴールのTo-beと現状のAs-isから課題を特定する。課題の解決状況を明確かつ定量的に測定できるようにする(KPI)。



課題解決のシナリオを描く:

As-isのプロセスを理解し、To-beに至るためのボトルネックを発見する。ボトルネックを解決するシナリオを描く。



MLのプロセスを特定する:

MLが貢献するプロセスを特定する。シナリオにおけるMLへの学習データ、入力、出力値(ex: 確率、予測値)を特定するモデルの要件は定量的に定める。

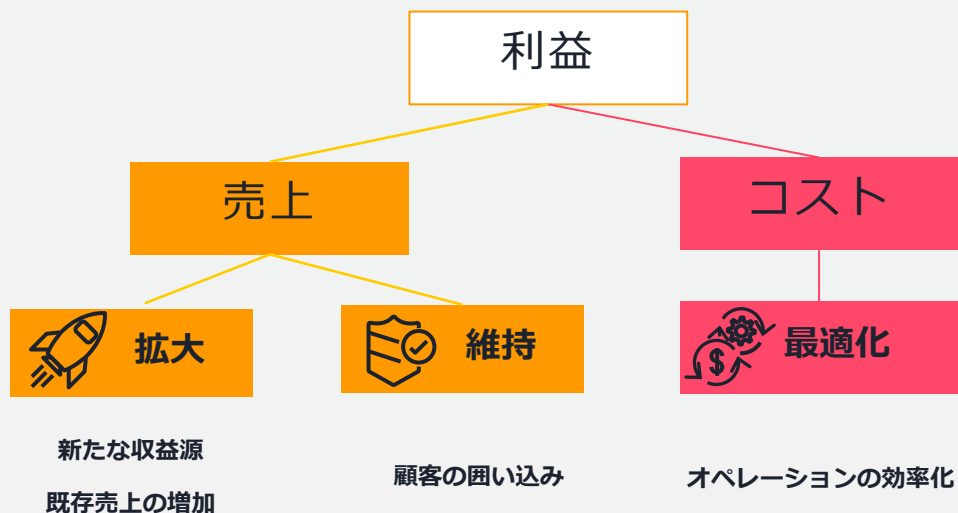
ビジネス課題を定義する

ビジネス課題はTo-beとAs-isのギャップにより定義される。

ビジネスKPIによる課題定義

To-beのKPIとAs-isのKPIのギャップ=課題

Ex: To-beの利益率はx%だがAs-isはy%である。



ユーザー体験による課題定義

To-beの体験とAs-isの体験のギャップ=課題

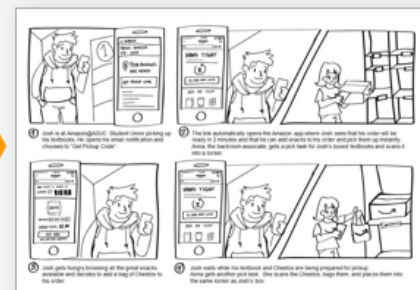
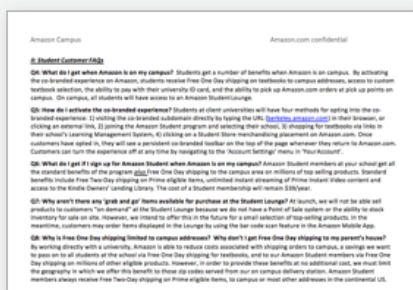
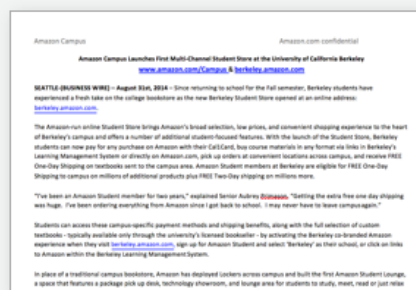
Ex: To-beは銀行口座があれば自動的に確定申告が完了するがAs-isはユーザー自身が事業経費を仕分けて申告する必要がある。



ビジネス課題を定義する: Amazon、AWSの場合

Working Backwards - お客様から考える

お客様に求められないモノやコトを作らないプロセス



お客様にこだわる
ための5つの質問

プレスリリース(PR)を
書く ※社内検討用

FAQを練る

ビジュアル(V)で
お客様体験を詰める

お客様は**誰**ですか？

お客様が抱える**課題**や**新しい可能性**は明確ですか？

お客様が受ける**価値**や**メリット**は明確ですか？

お客様の**ニーズ**や**ウォンツ**をどのように知りましたか？

お客様の**体験**はどのように変わりますか？

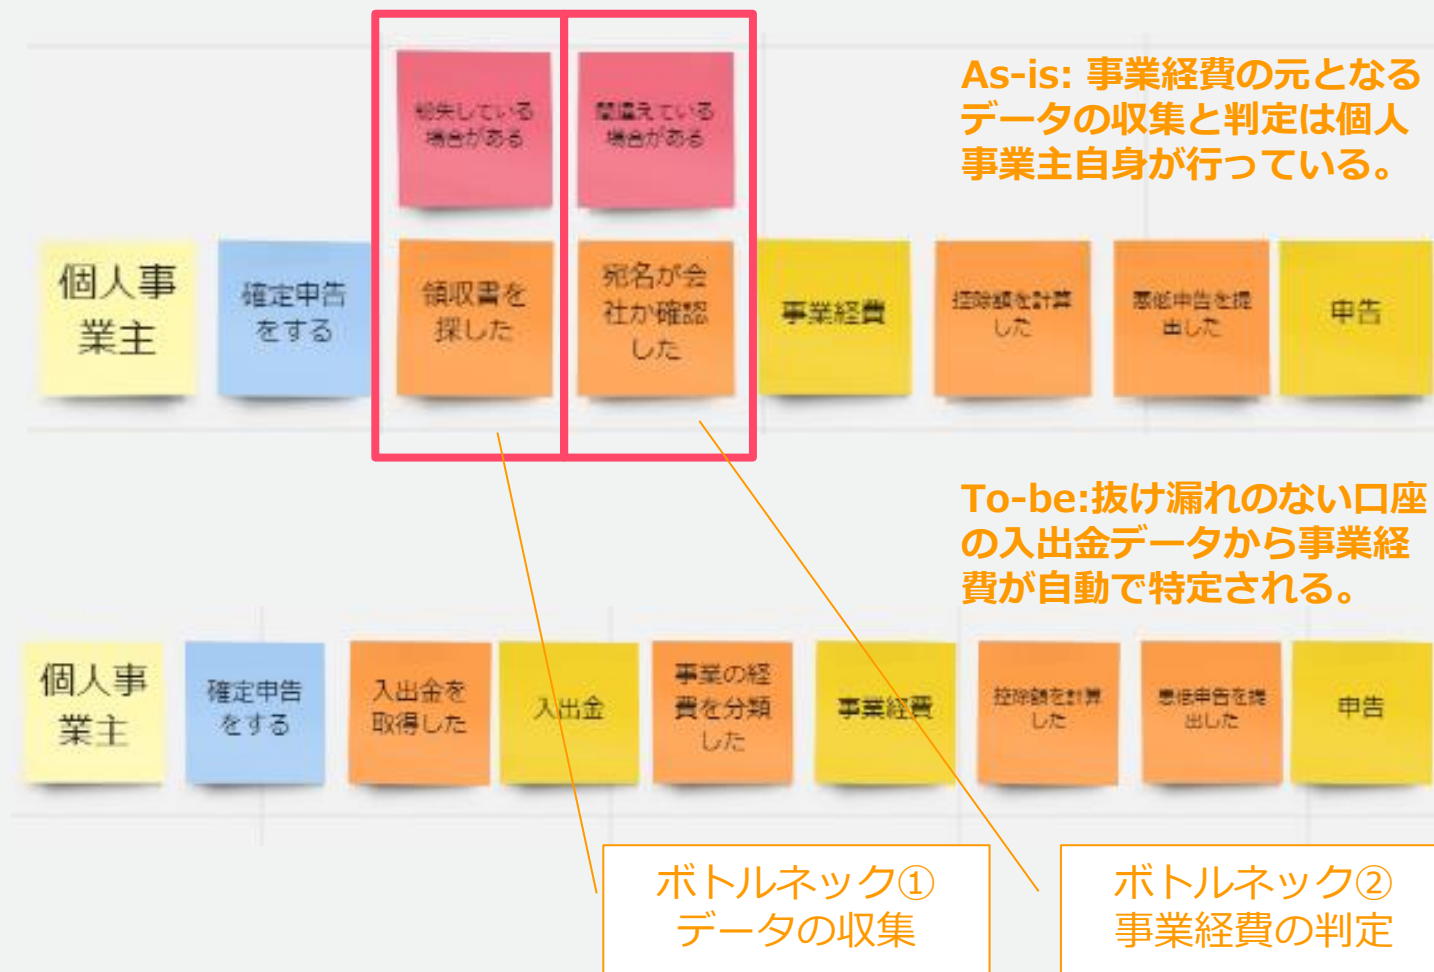
アウトプットをもとに、アイデアを練る

“プレスリリースを書き上げることが目的ではない
やる事を明確にするための発見や探求のプロセスのひとつ”

課題解決のシナリオを描く

As-isのプロセスを理解し、To-beに至るためのボトルネックを発見する。ボトルネックを解決するシナリオを描く。

As-isのプロセスを理解する方法は様々ある(ドメイン指向設計など。右図は [Event Storming](#) の例)。



課題解決のシナリオを描く：Event Stormingの例

Event Stormingは、複雑な業務を開発者とドメインエキスパート(業務エキスパート)が協力して明らかにするためのワークショップ。

Step1: Big Picture

主要なアクター(個人事業主/銀行など)が実行する操作に連なるイベントを時系列にならべる。

Step2: Process Modeling

操作に必要な情報、イベント間で受け渡す情報、イベントの分岐(ロジック)を追加する。

Step3: Software Design

イベントによって引き起こされる状態変化を特定する。

Step4: ドメインモデルを深く考える

Step5: イベントの整合性、モデルの妥当性を議論する

—————→ **1~5を繰り返す。**

MLのプロセスを特定する

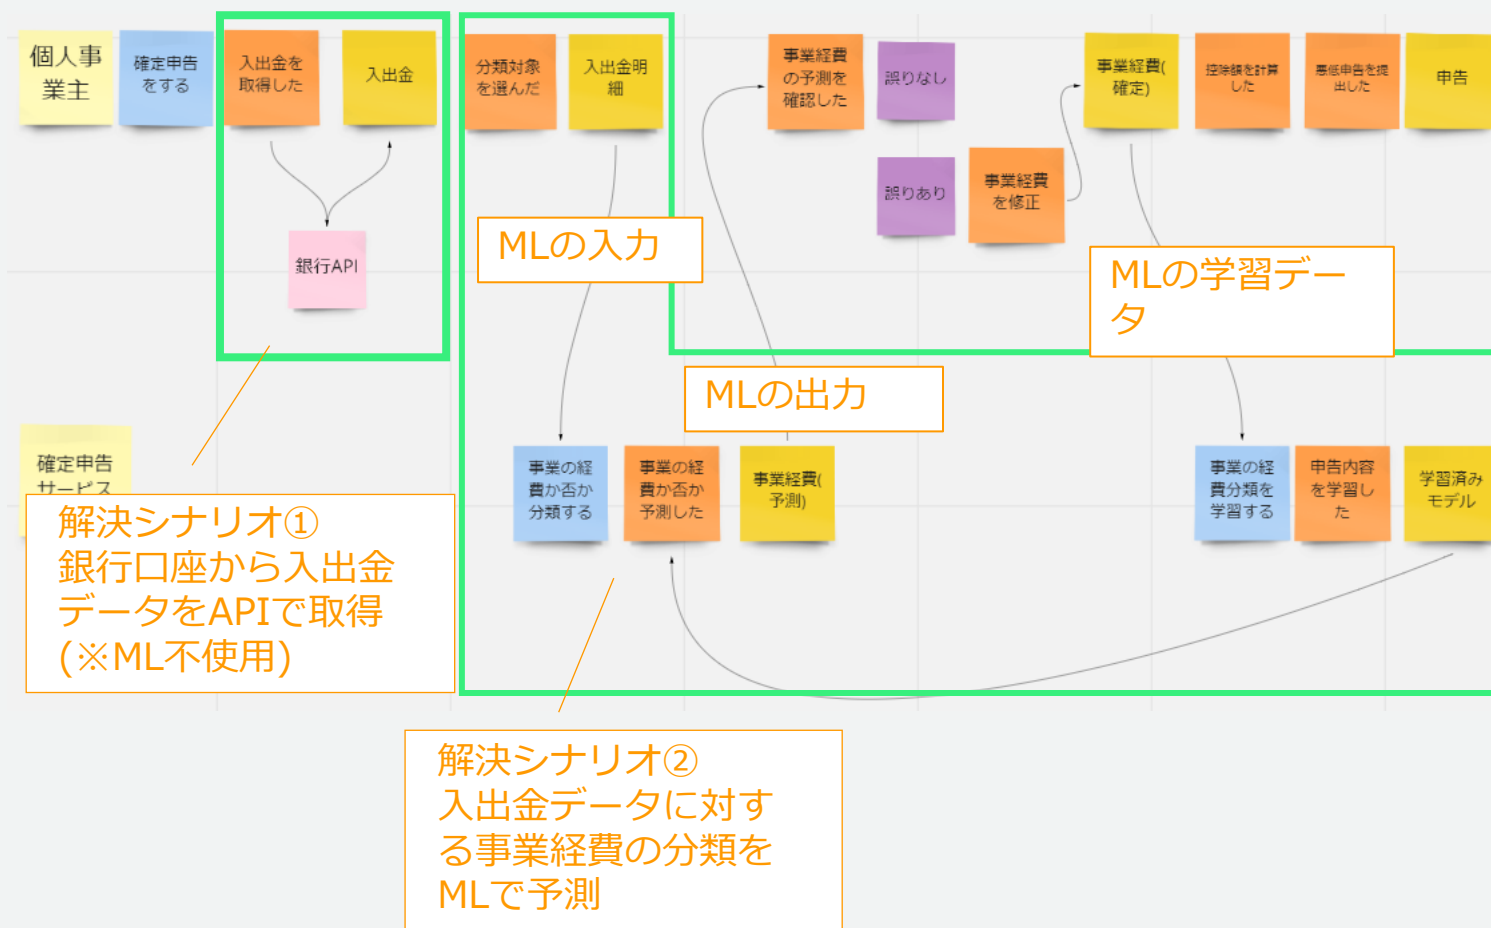
ボトルネックを解決するシナリオの中でMLが貢献するプロセスを特定する(解決のシナリオはもちろん、MLだけで構成されるわけではない)。

解決シナリオの中でMLの学習データ、MLへの入力、MLの出力(ex: 確率、予測値)を受け取るイベントを特定する。


※学習データがシナリオに登場しない場合、サービスが利用されるほど学習データが蓄積され精度が向上するサイクルを回せない。

モデルの要件を定量的に定める。

・2020~2021年度のX件の入出金データに対しF値y以上の精度を担保する、など。



MLの価値: MLの価値が高いシナリオに優先して取り組む



事業経費の分類をMLが予測するとき、

MLの価値=

確定申告する個人事業主の数

x 1人当たり入出金明細数

x 1明細当たり事業経費判定効果(削減時間等)

1) 対象となるユーザーが多いほど、2) 入出金明細が多いほど、3) 1明細当たりの効果が大きいほどMLの価値は高くなる。


1. ユースケースの特定

2. MLの要件


3. データの要件

4. 期間・実用化の要件


MLアイデア — MLを使うべき状況



複雑なロジック



スケーラビリティ



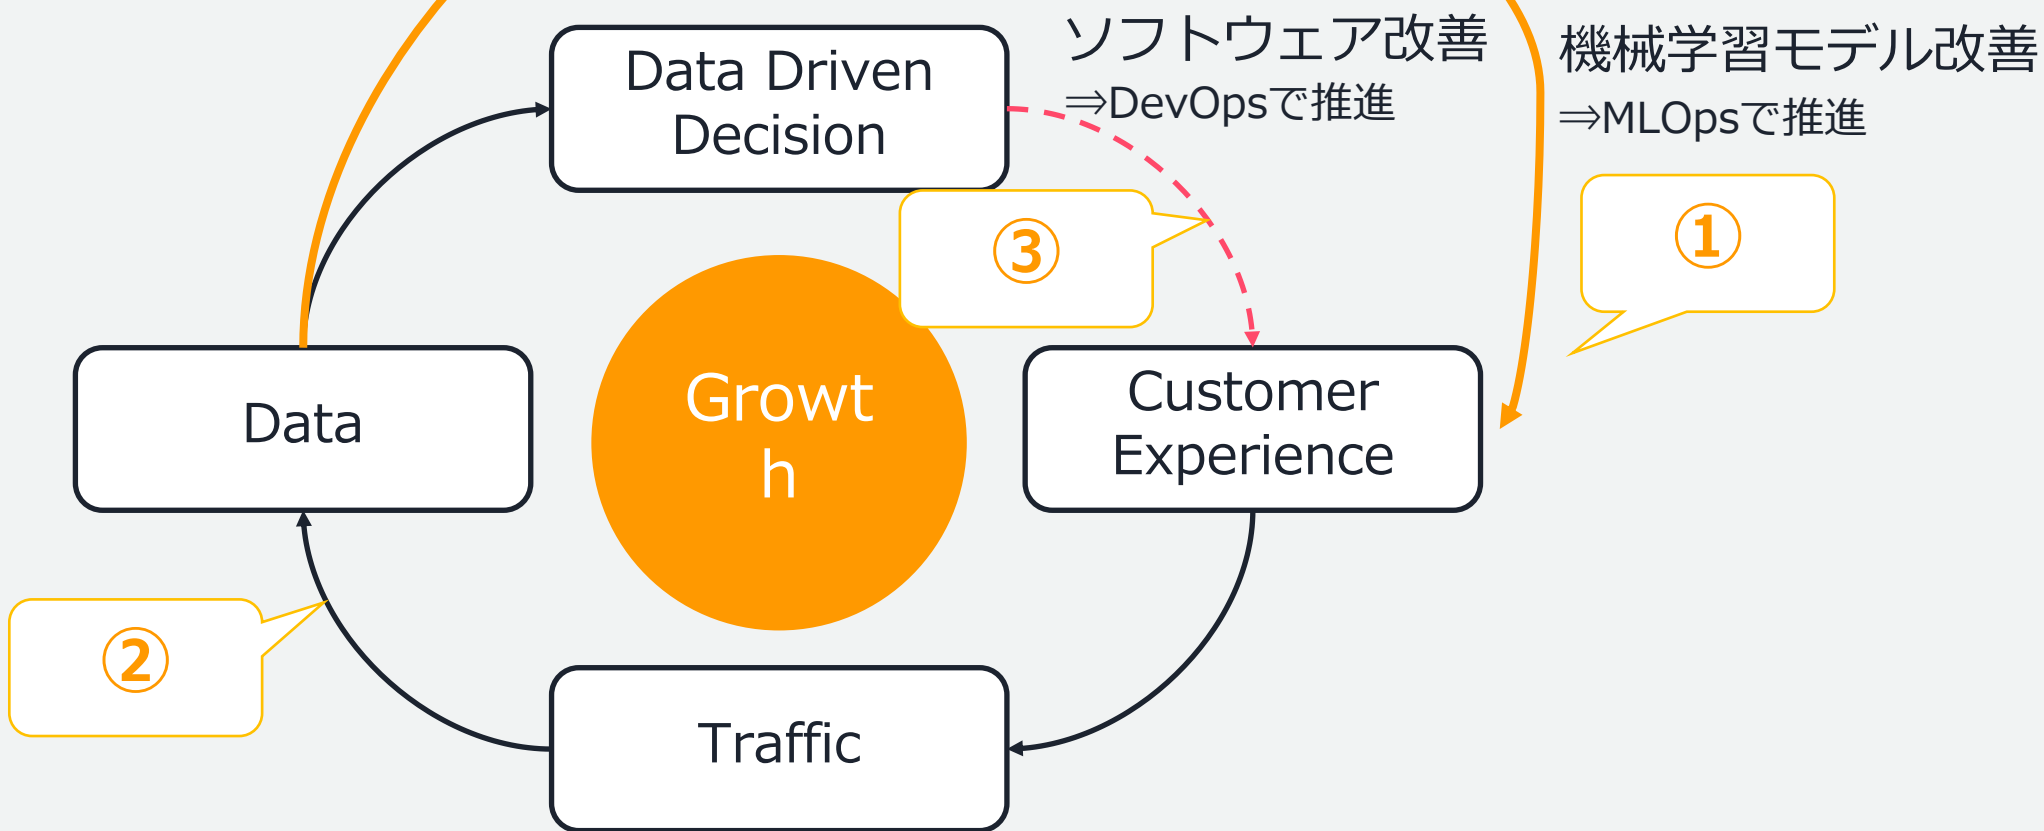
即時的な
レスポンス



パーソナライゼー
ション

MLの勝ちパターン

- ①機械学習がCustomer Experienceを改善しユーザー数が増える。
- ②増えたデータが学習データの源泉となる。
- ③モデルの改善速度と精度が、ソフトウェアによる改善を上回る。



MLの勝ちパターンが成立する条件


- ①機械学習によるCustomer Experienceの改善が進むほど、収益増につながる仕組みを作れている(スケーラビリティ/パーソナライゼーション)。
- ②サービスの機能や運用を通じ、学習データが半自動的に蓄積される仕組みが構築されている(即時的なレスポンス)。
- ③短期的に費用対効果の高いルールベースによる精度改善が、限界に達しつつあること(複雑なロジック)。

参考: 「[LayerX、ML\(機械学習\)を本気でやりますという話](#)」


MLアイデア — MLを使うべきではない状況




既存アルゴリズム
で解決可能



新たなデータへの
対応不要



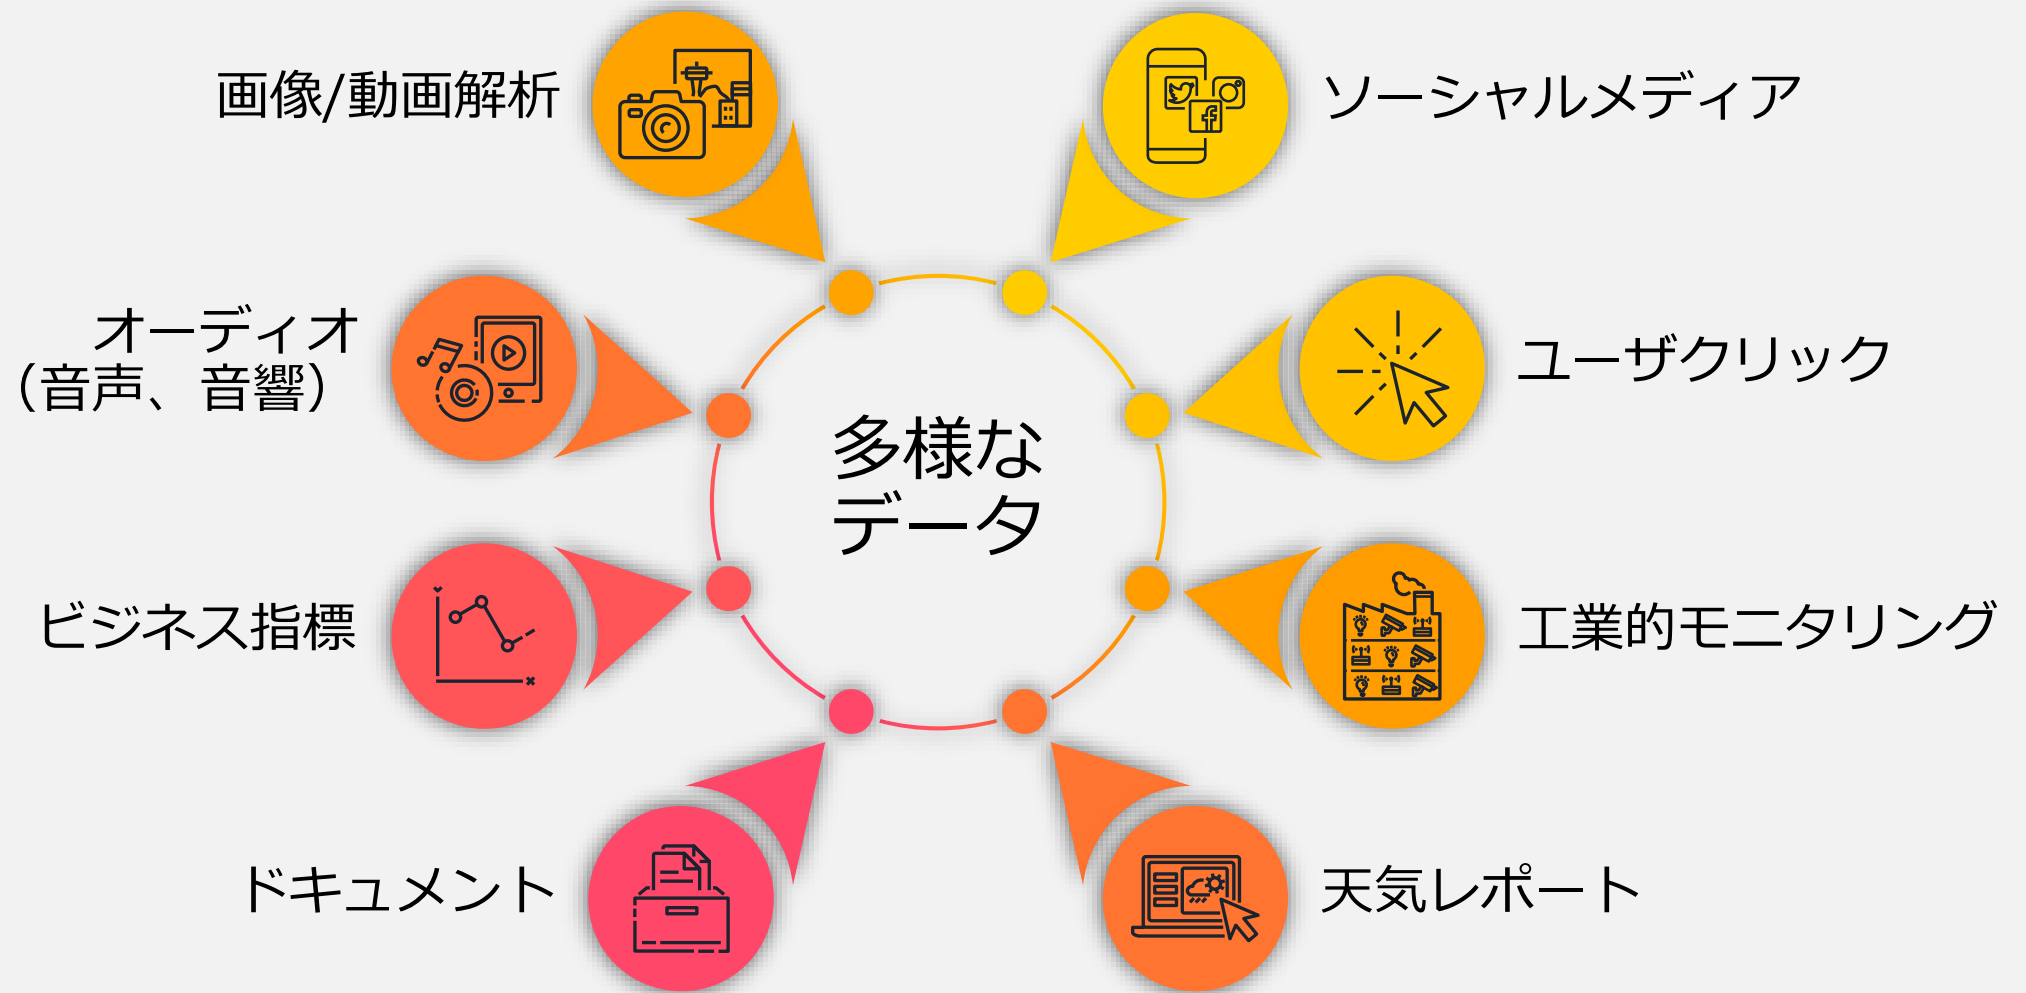
精度**100%**が
要求される



完全な説明性が
必要

1. ユースケースの特定
2. MLの要件
- 3. データの要件**
4. 期間・実用化の要件

データの現状を把握



データの準備状況

活用できる?



必要なデータが
存在する



簡単にアクセス
可能

活用に課題なし?




プライバシー
への配慮



セキュア

データの質は?



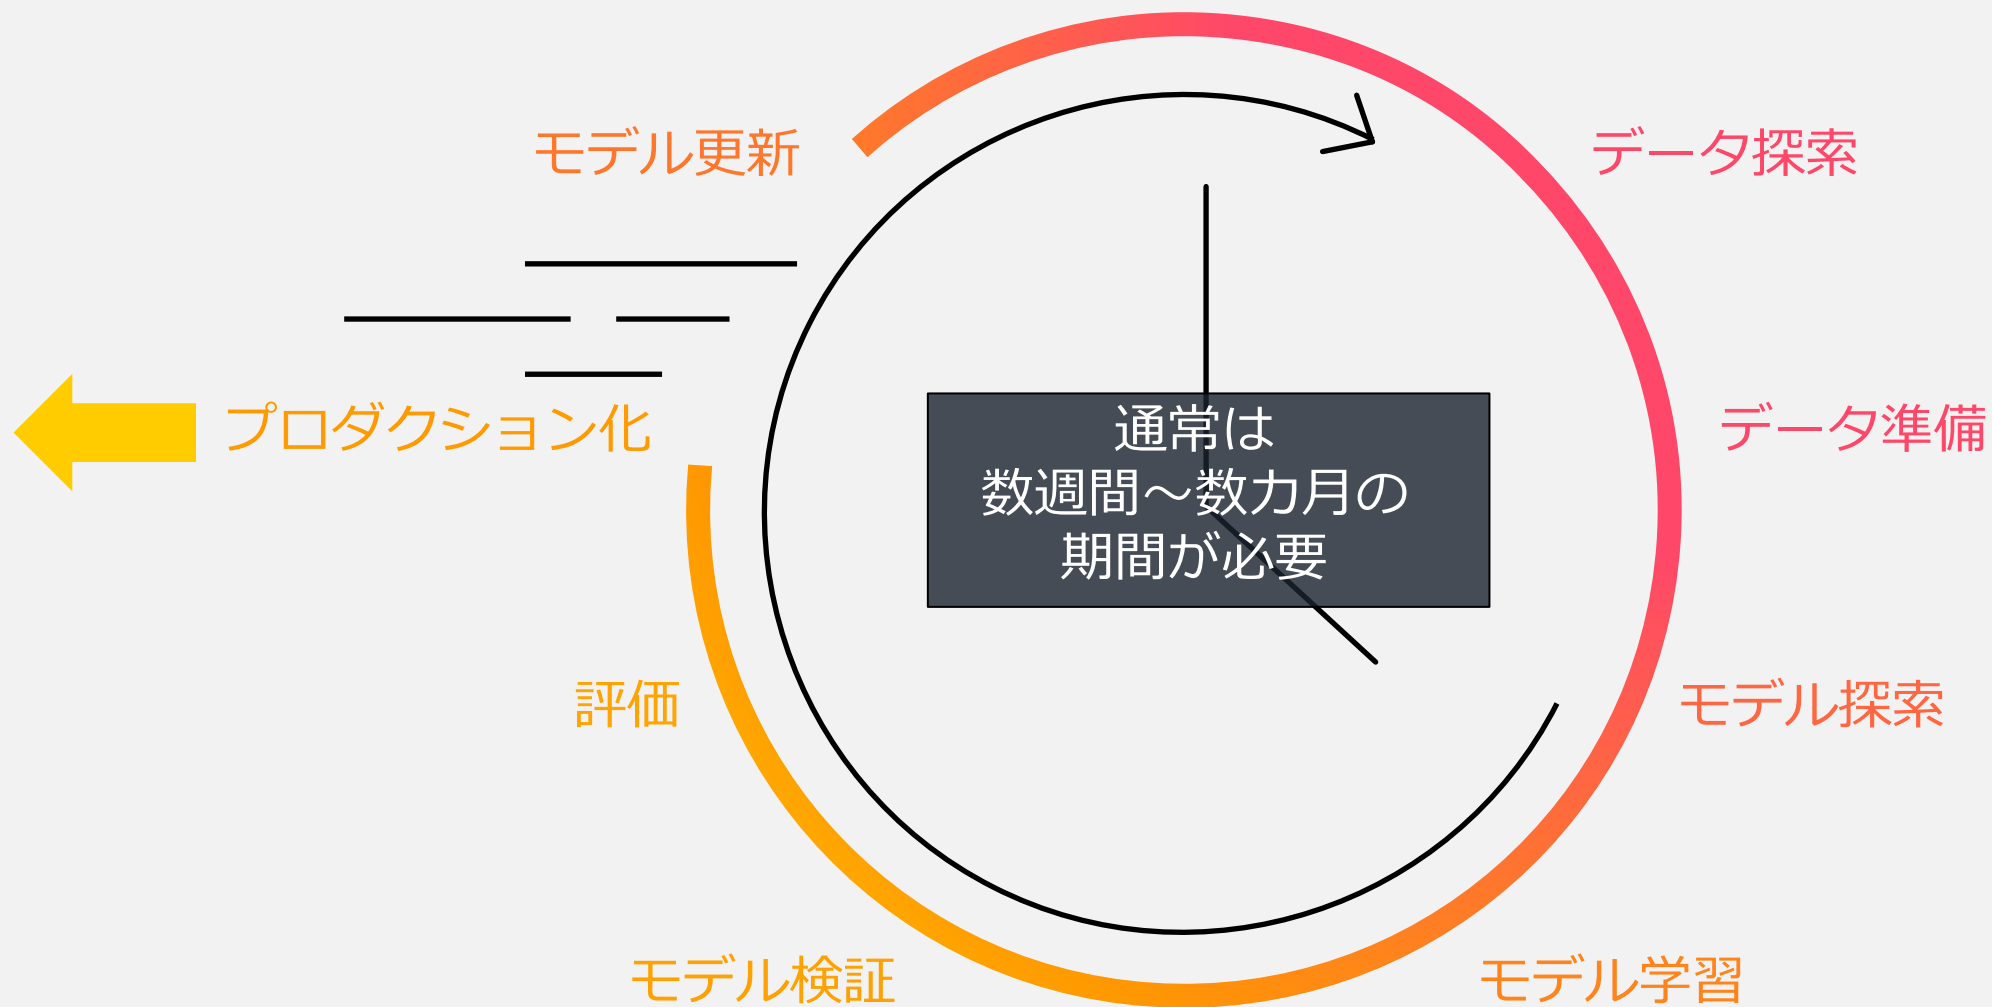
課題との関連性、
更新頻度




代表的かつ
偏りが無い

1. ユースケースの特定
2. MLの要件
3. データの要件
- 4. 期間・実用化の要件**

MLプロジェクトの工程



MVPまでのタイムライン（ベストケース）



よくある誤り：
MLモデル関連の期間のみを
見積る

プロジェクトの遅延要因

前頁はあくまでベストシナリオであり下記の要因により追加の期間が必要となる



前例のないタスク

深い科学的な知見が必要



探索時にデータの不備や
ラベル不足が発覚


解消に数カ月を
要することも



モデルの性能が
ビジネス要件を満たせない

追加実験の
繰り返しが必要

ケーススタディ：データ関連の遅延




ゴール:

ある製造業が製品の**画像をデータベース化**しており、
画像に基づく**不良品の検出**を
実現したい

課題:

画像データは製造ライン上に配置された
カメラにより、1カ月間自動的に撮影さ
れていたが、アノテーションが付与され
ていない

ケーススタディ：データ関連の遅延



結論：

MLモデルの学習のためには画像に対するラベリングが必要

ラベリングのためには、画像を正確に見極められる製造プロセスのエキスパートが必要

教訓：

- › MLプロジェクトの多くはラベル付きのデータが必要だが、容易にラベリングできないこともある
- › データとともにラベルを確実に収集することにより、プロセスを簡略化できる

実用化の要件



実験用コード

探索的

反復的

テスト、エラー対策少



プロダクション用コード

要件の確定

バージョン管理

実用レベルの信頼性

プロダクション化に関する疑問を早めに意識

- › モデルに基づく予測に必要な計算コストは？
- › データはどのくらいの頻度で変わる？
- › プロダクション化のために必要な変化は？
- › モデルの性能はビジネスニーズを満たしている？

ナレッジチェック: モデル開発プロセス

モデル開発に取り掛かる前に行っておくステップは？

- a) モデル検証
- b) モデルデプロイメント
- c) ビジネス課題定義
- d) データ準備

ナレッジチェック: モデル開発プロセス

モデル開発に取り掛かる前に行っておくステップは？

- a) モデル検証
- b) モデルデプロイメント
- c) ビジネス課題定義
- d) データ準備

1. ユースケースの特定


2. MLの要件

3. データの要件

4. 期間・実用化の要件

Module #2の復習

Module #2: MLプロジェクトの計画策定



本モジュールの学び:

- › MLのユースケースを特定する方法
- › MLの要件
 - › ユースケースとの適合性の評価
- › データの要件
 - › MLに必要なデータの評価
- › 期間・実用化の要件
 - › MLソリューション開発のタイムライン
 - › 初期段階におけるプロダクション化のための質問

TIME FOR A BREAK

See you in 5 minutes!

This material is based on the AWS Machine Learning Embark Program,
an immersive ML training program provided by Amazon Machine Learning Solutions Lab

